

多项式非线性 Tucker 分解

申开宇

2026 年 4 月 14 日

摘要

经典 Tucker 分解以多线性低秩结构为核心，但当观测张量来源于非线性生成、饱和响应、复杂高阶交互或异方差扰动时，纯多线性假设往往会产生系统性失配。针对这一问题，本文提出多项式链接的非线性 Tucker 分解模型 NTD-PL (Nonlinear Tucker Decomposition with Polynomial Links)。该模型保留共享的 Tucker 潜在张量作为低秩骨架，并在其上施加显式的多项式链接，从而将标准 Tucker 作为线性特例纳入统一框架，并以少量链接系数实现对高阶交互的受控扩展。

理论上，本文说明了 NTD-PL 与 Tucker 的嵌套关系，给出了多项式生成情形下的精确表达结果，以及解析函数情形下的有限阶截断逼近界；同时构建了统一的带掩码学习目标，并结合 Tucker 初始化、梯度更新与多项式系数的更新，给出了可实现的交替优化方法。实验结果表明：在线性源数据下，NTD-PL 与 Tucker 基本重合，不会制造伪增益；在统一非线性残差协议下，NTD-PL 在结构匹配与有限阶逼近两类情形中均取得稳定收益；在真实高光谱重构与随机缺失补全任务上，NTD-PL 在同参数预算下持续优于 Tucker。进一步的机制对照表明，这种收益既不能归因于单纯增参，也不能由对 Tucker 输出施加一次共享多项式校正所替代。

总体而言，本文为保持 Tucker 骨架而增强非线性生成机制提供了一种显式、低维、可分析的结构化方案。

目录

1	引言	4
2	相关工作	6
3	记号和预备	8
3.1	记号约定	8
3.2	张量基本运算	8
3.3	Tucker 分解与带掩码观测	9
3.4	逐元素多项式链接	10
4	提出的方法	12
4.1	设计动机：显式高阶交互	12
4.2	NTD-PL 模型定义与结构解释	13
4.2.1	模型定义	13
4.2.2	作为 p -Tucker 的结构化压缩	13
4.3	NTD-PL 的基本性质	14
4.3.1	模型族关系与参数效率	14
4.3.2	非线性生成下的表达能力	14
4.3.3	尺度不定性与归一化机制	15
4.4	统一学习目标与优化算法	15
4.4.1	统一学习目标	15
4.4.2	初始化	16
4.4.3	核心与因子的更新	16
4.4.4	多项式系数的更新	17
4.4.5	因子归一化与核心吸收	17
4.4.6	次数延续策略	17
4.4.7	算法复杂度分析	17
5	实验	20
5.1	实验设置	20
5.2	可控合成数据实验	21
5.2.1	线性一致性验证	21
5.2.2	非线性映射匹配与逼近实验	21
5.3	高光谱数据上的非线性低秩重构与补全	24
5.3.1	数据与协议	24
5.3.2	全观测重构	24
5.3.3	随机观测补全	27
5.3.4	多项式后处理的机制区分	28
5.3.5	优势出现的位置	29
5.3.6	多项式次数考察	29
5.3.7	跨数据集的鲁棒性验证	30
6	结论	32

A	NTD-PL 的基本模型性质	36
A.1	退化到 Tucker 与嵌套模型族	36
A.2	参数复杂度	36
A.3	尺度不定性与归一化机制	37
B	逐元素非线性生成下的表达性分析	37
B.1	多项式生成下的精确表达	38
B.2	一般逐元素非线性下的逼近界	39
B.3	解析函数下的显式截断误差界	39
B.4	与非线性能量占比参数 α 的关系	40
C	优化补充	42
C.1	β 子问题的唯一解	42
D	实验补充图表	43
D.1	合成实验补充	43
D.2	真实高光谱实验补充	45

1 引言

张量分解为多维数据提供了自然的低秩表示方式，已广泛应用于图像恢复、信号处理、压缩表示与缺失补全等任务^[1-5]。作为经典模型之一，Tucker 分解通过核心张量与模因子矩阵刻画多模之间的耦合关系，在结构可解释性、秩控制灵活性与算法可实现性之间取得了良好平衡^[6-8]。然而，标准 Tucker 分解本质上建立在多线性条目生成假设之上；当观测张量来源于非线性生成、饱和响应、复杂高阶交互或异方差扰动时，纯多线性模型往往会产生系统性失配，进而限制其在重建、恢复与后续预测任务中的表现。

为缓解这一问题，近年来出现了多种非线性张量分解方法。现有工作一方面通过链接函数、广义似然、核方法或高斯过程改变潜在线性预测到观测条目的映射，另一方面也通过深度先验、神经解码器或网络化分解结构提升模型表达力^[9-13]。这些方法表明，非线性扩展确实能够显著增强张量模型对复杂数据机制的适应性；但与此同时，它们通常也伴随更高的推断与训练复杂度、更大的超参数设计空间，或对经典 Tucker 结构透明性的削弱。因而，一个仍然值得回答的问题是：能否在尽量保留 Tucker 低秩骨架、参数效率与多模可解释性的前提下，为其引入受控而有效的非线性表达能力？这也是本文的出发点。

本文提出多项式链接的非线性 Tucker 分解（Nonlinear Tucker Decomposition with Polynomial Links, NTD-PL）。该模型以共享的 Tucker 潜在张量

$$\mathcal{S} = \mathcal{X} \times_1 \mathbf{A}^{(1)} \times_2 \cdots \times_N \mathbf{A}^{(N)}$$

作为低秩骨架，并在其上施加显式的逐元素多项式链接

$$\hat{\mathcal{Y}} = f_{\beta}(\mathcal{S}) = \sum_{p=0}^P \beta_p \mathcal{S}^{\odot p}.$$

由此，标准 Tucker 被自然包含为线性特例，而高阶非线性则通过少量链接系数以受控方式引入。与依赖核/高斯过程的非参数映射不同，NTD-PL 的非线性形式是显式、低维且确定性的；与依赖神经解码器的深度非线性模型不同，NTD-PL 并不替换 Tucker 的低秩骨架，而是仅对条目生成机制进行结构化增强。因而，它更适合被理解为一种增强 Tucker 的模型，而非对 Tucker 的完全替代。

这一建模方式的关键在于，它并不是简单地对 Tucker 重构结果施加逐元素后处理。由于潜在张量 $\mathcal{S}$ 的每个条目本身已经由核心张量与各模因子的多线性耦合生成，因此 $\mathcal{S}^{\odot p}$ 对应的是共享低秩骨架上的高阶交互重组，而不是独立于低秩结构之外的外部校正。正因如此，NTD-PL 在不显式引入高阶因子张量的情况下，仍能够获得超出纯多线性模型的表达能力，同时保持与 Tucker 同量级的参数化骨架。

围绕该模型，本文进一步刻画了其若干基本性质。首先，NTD-PL 与标准 Tucker 构成清晰的嵌套关系：当高阶系数关闭时，模型精确退化为 Tucker；随着多项式次数增加，模型类按次数形成受控扩张。其次，在观测张量由逐元素多项式函数作用于某个 Tucker 潜在张量生成时，NTD-PL 可在相应阶数下实现精确匹配；当生成函数为解析函数时，有限阶多项式链接可给出系统逼近，并具有显式截断误差界。再次，为了同时适用于完整张量分解与带掩码观测的张量补全，本文构建了统一的学习目标，并结合系数 ridge 更新、因子归一化与次数延续策略给出可实现的优化框架。

实验结果进一步支持了上述建模与理论分析。在可控合成实验中，NTD-PL 在严格线性数据上与 Tucker 保持一致，并在多项式与平滑非线性残差下随非线性强度增大持续优于 Tucker、CP、TT 和 TR 等基线，且其性能提升与目标函数的主导阶次相一致。在真实高光谱数据上，NTD-PL 在 CAVE 数据集的全观测重构与随机缺失补全任务中均稳定优于 Tucker，这种增益不仅体现在场景均值上，也在多数场景、多个缺失率和局部空间区域上保持一致。进一步的机制分析表明，该优势并不能由对 Tucker 输出施加简单多项式后处理所替代，而主要来源于显式非线性链接与共享低秩骨架的联合建模；跨数

据集实验则说明，该方法在多数真实场景中有效，同时也呈现出清晰的适用边界。本文的主要贡献概括如下。

1. 提出 NTD-PL，一种在共享 Tucker 潜在张量上施加显式逐元素多项式链接的非线性低秩张量模型。
2. 说明该模型与 Tucker 的嵌套关系、参数规模特征，以及其在多项式生成和解析函数生成情形下的表达性质。
3. 给出统一的带掩码学习形式，使模型能够同时处理完整张量分解与张量补全。
4. 通过可控合成实验与真实高光谱实验验证了该模型的有效性与适用边界。

本文其余部分安排如下：第二节综述相关工作；第三节给出记号与预备知识；第四节介绍模型、性质与优化方法；第五节报告实验结果；第六节总结全文并讨论后续工作。

2 相关工作

以非线性被引入到模型的层次的视角来看, 现有非线性张量分解方法大致可归纳为四类。第一类方法在保留低秩因子骨架的前提下, 直接修改潜在线性预测到观测条目的映射方式, 即将非线性放在条目生成层。较早的一类工作通过广义损失或广义似然扩展经典分解模型, 例如 generalized CP decomposition^[9] 在保留低秩参数化的同时, 以更一般的观测损失替代平方误差, 使模型能够适应二值、计数和鲁棒建模等场景; Bayesian Poisson Tucker decomposition^[14] 则在 Tucker 框架下引入 Poisson 观测模型与层次贝叶斯结构, 用于计数型多维事件数据建模。进一步地, InfTucker^[10]、Distributed Flexible Nonlinear Tensor Factorization^[15] 与 Streaming Nonlinear Bayesian Tensor Decomposition^[16] 通过核方法、高斯过程或其稀疏近似, 在条目层引入更强的非参数非线性表达。总体而言, 这一路线与本文最为接近, 因为它们都试图在不完全放弃低秩张量骨架的情况下增强观测生成机制; 但相应代价通常是更重的推断过程、更多的核或变分超参数, 以及相对较弱的结构透明性。

第二类方法将非线性放在因子本身的生成、约束或组织方式中, 其核心是改变因子的构造方式。这类方法通常通过深度先验、时序网络或几何流形假设, 把传统线性因子空间弯曲为受约束的非线性表示空间。典型地, DeepTensor^[11] 令低秩因子由深度网络生成, 利用深度先验的隐式正则化来弥补经典低秩模型在复杂信号结构上的表达不足; Neural Tensor Factorization^[17] 以及 DeepCP^[18] 则将嵌入、时间依赖和神经网络生成机制结合起来, 以适应时序交互和带噪观测场景; Neural Additive Tensor Decomposition^[19] 试图在表达能力与可解释性之间取得折中, 通过对潜在成分施加神经网络变换来增强稀疏张量建模能力。另一些工作则更强调几何结构, 例如 3D head pose estimation 中的张量分解与非线性流形建模^[20], 通过对姿态因子施加显式流形约束来提升泛化与可解释性。相比条目层非线性, 这类方法往往具有更高的建模自由度, 但同时也更依赖网络结构设计或先验选择, 理论分析和优化稳定性也更复杂。

第三类方法进一步将张量分解算子本身网络化, 即把非线性直接嵌入到模乘、核收缩或层级分解结构内部, 形成深度张量模型。其代表思想不是在传统低秩分解外部附加一个非线性部件, 而是把 Tucker、TT 等结构重新组织为多层、可堆叠的非线性变换单元。比如, Stacked Tucker Decomposition^[21] 在模乘之后插入非线性激活, 并通过层级堆叠构造深度化的 Tucker 结构; NMTucker^[12] 在 Matryoshka 式 Tucker 框架中显式引入非线性组件, 以改善高稀疏补全任务中的表达能力; Nonlinear Tensor Train^[22] 则在 TT 核收缩之间加入激活, 用于深度网络压缩与表示学习。与前两类方法相比, 这一路线的优势在于能够在保持张量参数共享结构的同时获得接近深度网络的表达能力, 但其代价是削弱了经典低秩模型在参数含义、结构解析和理论刻画上的直接性。

第四类方法并不一定直接修改张量分解本身, 而是将张量视为表示外部非线性结构的紧凑载体, 再通过分解实现高效建模与计算。这类方法常见于多项式系统、Volterra 系统、非线性变换域表示等场景, 其中非线性结构通常先由物理机制、解析展开或前端变换给定, 张量主要负责高阶系数的压缩表示与数值加速。典型如 TNMOR 和 STORM^[23-24], 它们先对非线性电路或动力系统作多项式/Taylor/Volterra 展开, 再将各阶系数重排为高阶张量并做 CP 或对称分解, 从而构造保留高阶非线性的降阶模型; 另一类工作如多维非线性变换张量表示^[25], 则通过卷积网络和激活函数构造数据自适应的非线性变换域, 再在该域内施加张量低秩约束。总体来看, 这些方法说明张量不仅可以作为非线性分解器, 也可以作为非线性结构的压缩表达工具; 但在多数情形下, 非线性的来源位于张量模型之外, 而非在经典 Tucker 骨架内部形成一个受控、显式且可直接解释的条目级扩展。

与上述工作相比, NTD-PL 的定位更接近保留 Tucker 骨架的条目生成机制扩展, 但又与广义似然、核方法、高斯过程和深度解码器等路线有所区别。本文并不依赖无限维核映射、重型概率推断或深度生成网络, 而是在共享 Tucker 潜在张量之上引入显式、有限阶、逐元素的多项式链接, 使非线性能力以少量系数受控进入模型。这一设计使得 NTD-PL 一方面继承了 Tucker 的低秩结构、参数效率与多模可解释性, 另一方面又能够通过明确的阶数展开刻画条目层残差、给出与 Tucker 的嵌套关系以

及相应的逼近分析。就现有文献而言，NTD-PL 的创新点正在于：它不是将非线性完全外包给核函数、神经网络或外部多项式系统，而是在经典 Tucker 框架内部构造了一个显式、可分析、可逐阶控制的非线性链接机制，从而在表达能力、结构透明性与优化可实现性之间取得新的折中。

3 记号和预备

本章给出全文使用的主要记号、基本张量运算以及后续构造 NTD-PL 所需的预备定义。除特别说明外，所有张量、矩阵与向量均取值于实数域 $\mathbb{R}$ 。本章内容的目的是统一第四章中将反复使用的符号系统与基础运算形式。

3.1 记号约定

对于变量， $N \geq 3$ 阶张量记为书法体字母，如 $\mathcal{X}, \mathcal{Y}$ ；矩阵记为大写粗体字母，如 $\mathbf{A}, \mathbf{X}$ ；向量记为小写粗体字母，如 $\mathbf{x}, \mathbf{a}$ ；标量记为小写斜体字母，如 x, a 。对于维度、秩、次数等非变量量，通常以大写字母表示其取值，以对应的小写字母表示索引，例如 I_n 表示第 n 模维度， $i_n \in [I_n]$ 表示对应索引，其中

$$[I_n] := \{1, 2, \dots, I_n\}.$$

类似地， R_n 表示第 n 模的多线性秩， $r_n \in [R_n]$ 表示对应的潜在索引。

给定 N 阶张量

$$\mathcal{X} \in \mathbb{R}^{I_1 \times \dots \times I_N},$$

其元素记为

$$x_{i_1 \dots i_N} \quad \text{或} \quad \mathcal{X}[i_1, \dots, i_N].$$

当需要压缩书写时，记多指标为

$$\mathbf{i} = (i_1, \dots, i_N), \quad x_{\mathbf{i}} := x_{i_1 \dots i_N}.$$

对于逐元素运算，记 Hadamard 乘积为 $\odot$ 。若 $\mathcal{X}$ 与 $\mathcal{Y}$ 形状相同，则

$$(\mathcal{X} \odot \mathcal{Y})_{\mathbf{i}} = x_{\mathbf{i}} y_{\mathbf{i}}.$$

进一步地，定义张量的逐元素幂为

$$\mathcal{X}^{\odot p}, \quad (\mathcal{X}^{\odot p})_{\mathbf{i}} = x_{\mathbf{i}}^p,$$

其中 $p \in \mathbb{N}$ 。特别地，约定

$$\mathcal{X}^{\odot 0} = \mathbf{1},$$

其中 $\mathbf{1}$ 表示与 $\mathcal{X}$ 同形状的全 1 张量。

对于观测不完整情形，记观测集合为

$$\Omega \subseteq [I_1] \times \dots \times [I_N],$$

对应的掩码张量记为

$$\mathcal{M} \in \{0, 1\}^{I_1 \times \dots \times I_N}, \quad m_{\mathbf{i}} = \begin{cases} 1, & \mathbf{i} \in \Omega, \\ 0, & \mathbf{i} \notin \Omega. \end{cases}$$

3.2 张量基本运算

模 n 展开与向量化。 给定张量 $\mathcal{X} \in \mathbb{R}^{I_1 \times \dots \times I_N}$ ，其模 n 展开记为

$$\mathbf{X}_{(n)} \in \mathbb{R}^{I_n \times K_n}, \quad K_n := \prod_{m \neq n} I_m.$$

本文统一采用固定的索引排列顺序来定义展开与向量化；一旦顺序固定，所有由展开诱导的矩阵表达式均相应唯一。张量 $\mathcal{X}$ 的向量化记为

$$\text{vec}(\mathcal{X}) \in \mathbb{R}^{\prod_{n=1}^N I_n}.$$

Frobenius 范数. 张量 $\mathcal{X}$ 的 Frobenius 范数定义为

$$\|\mathcal{X}\|_F := \left(\sum_{i_1, \dots, i_N} x_{i_1 \dots i_N}^2 \right)^{1/2},$$

它与任意模展开的矩阵 Frobenius 范数一致, 即

$$\|\mathcal{X}\|_F = \|\mathbf{X}_{(n)}\|_F.$$

模 n 乘积. 设

$$\mathcal{X} \in \mathbb{R}^{I_1 \times \dots \times I_n \times \dots \times I_N}, \quad \mathbf{A} \in \mathbb{R}^{J \times I_n},$$

则 $\mathcal{X}$ 与 $\mathbf{A}$ 的模 n 乘积记为 $\mathcal{X} \times_n \mathbf{A}$, 其结果属于

$$\mathbb{R}^{I_1 \times \dots \times I_{n-1} \times J \times I_{n+1} \times \dots \times I_N},$$

并按元素定义为

$$(\mathcal{X} \times_n \mathbf{A})_{i_1 \dots i_{n-1} j i_{n+1} \dots i_N} = \sum_{i_n=1}^{I_n} x_{i_1 \dots i_n \dots i_N} a_{j i_n}.$$

模 n 展开下, 该运算满足

$$(\mathcal{X} \times_n \mathbf{A})_{(n)} = \mathbf{A} \mathbf{X}_{(n)}.$$

Kronecker 积. 对矩阵 $\mathbf{A} \in \mathbb{R}^{I \times R}$ 与 $\mathbf{B} \in \mathbb{R}^{J \times S}$, 其 Kronecker 积记为

$$\mathbf{A} \otimes \mathbf{B} \in \mathbb{R}^{IJ \times RS}.$$

后文在展开 Tucker 模型与写出向量化表达时将频繁使用该记号。

3.3 Tucker 分解与带掩码观测

Tucker 分解. 给定观测张量

$$\mathcal{Y} \in \mathbb{R}^{I_1 \times \dots \times I_N},$$

Tucker 分解将其近似为

$$\hat{\mathcal{Y}} = \llbracket \mathcal{X}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket := \mathcal{X} \times_1 \mathbf{A}^{(1)} \times_2 \dots \times_N \mathbf{A}^{(N)},$$

其中

$$\mathcal{X} \in \mathbb{R}^{R_1 \times \dots \times R_N}, \quad \mathbf{A}^{(n)} \in \mathbb{R}^{I_n \times R_n}, \quad n = 1, \dots, N.$$

向量

$$(R_1, \dots, R_N)$$

称为 Tucker 分解的多线性秩。为简洁起见, 后文记

$$\mathcal{T}(\mathcal{X}, \{\mathbf{A}^{(n)}\}) := \llbracket \mathcal{X}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket.$$

展开形式. Tucker 模型在模 n 展开下可写为

$$\hat{\mathbf{Y}}_{(n)} = \mathbf{A}^{(n)} \mathbf{X}_{(n)} (\mathbf{A}^{(N)} \otimes \dots \otimes \mathbf{A}^{(n+1)} \otimes \mathbf{A}^{(n-1)} \otimes \dots \otimes \mathbf{A}^{(1)})^\top.$$

相应地, 其向量化形式为

$$\text{vec}(\hat{\mathcal{Y}}) = (\mathbf{A}^{(N)} \otimes \dots \otimes \mathbf{A}^{(1)}) \text{vec}(\mathcal{X}).$$

上述等价表达在后文的复杂度分析、子问题推导与实现中都将用到。

全观测与带掩码观测. 在全观测情形下, 标准 Tucker 拟合可写为

$$\min_{\mathcal{X}, \{\mathbf{A}^{(n)}\}} \frac{1}{2} \|\mathcal{Y} - \mathcal{T}(\mathcal{X}, \{\mathbf{A}^{(n)}\})\|_F^2.$$

在带掩码观测情形下, 相应目标写为

$$\min_{\mathcal{X}, \{\mathbf{A}^{(n)}\}} \frac{1}{2} \|\mathcal{M} \odot (\mathcal{Y} - \mathcal{T}(\mathcal{X}, \{\mathbf{A}^{(n)}\}))\|_F^2.$$

因此, 掩码张量 $\mathcal{M}$ 仅决定哪些条目参与损失计算, 而不改变 Tucker 骨架本身。本文后续的 NTD-PL 也将沿用这一统一形式来同时处理完整张量分解与张量补全。

尺度不定性说明. 与标准 Tucker 一样, 上述分解具有固有的尺度不定性: 某一模因子中的缩放可通过核心张量中的反向缩放被抵消, 而不改变最终重构结果。本文在第四章中将进一步说明 NTD-PL 在此基础上的尺度问题及其归一化处理。

3.4 逐元素多项式链接

为后续定义 NTD-PL, 先给出逐元素多项式链接的基本形式。设

$$P \in \mathbb{N}$$

为最大多项式次数, $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_P)^\top \in \mathbb{R}^{P+1}$ 为链接系数。对任意标量 $t \in \mathbb{R}$, 定义多项式链接函数

$$f_{\boldsymbol{\beta}}(t) = \sum_{p=0}^P \beta_p t^p.$$

将其逐元素作用到张量

$$\mathcal{S} \in \mathbb{R}^{I_1 \times \dots \times I_N}$$

上, 定义

$$f_{\boldsymbol{\beta}}(\mathcal{S}) := \sum_{p=0}^P \beta_p \mathcal{S}^{\odot p}.$$

按元素写为

$$(f_{\boldsymbol{\beta}}(\mathcal{S}))_{\mathbf{i}} = \sum_{p=0}^P \beta_p s_{\mathbf{i}}^p.$$

这一构造保留了输入张量 $\mathcal{S}$ 的形状不变, 仅改变每个条目的生成方式, 因此适合与 Tucker 潜在张量组合使用。特别地, 当

$$\beta_1 = 1, \quad \beta_p = 0 \quad (p \neq 1)$$

时,

$$f_{\boldsymbol{\beta}}(\mathcal{S}) = \mathcal{S},$$

此时逐元素多项式链接退化为恒等映射; 因此, 标准 Tucker 可被视为后续 NTD-PL 的线性特例。

为便于后续写出系数子问题, 还可对任一标量 s 定义其多项式特征向量

$$\boldsymbol{\phi}(s) = [1, s, s^2, \dots, s^P]^\top \in \mathbb{R}^{P+1}.$$

若将 $\mathcal{S}$ 的全部条目按固定顺序排成向量

$$\mathbf{s} = \text{vec}(\mathcal{S}),$$

则相应可定义设计矩阵

$$\mathbf{\Phi}(\mathcal{S}) = \begin{bmatrix} \phi(s_1)^\top \\ \phi(s_2)^\top \\ \vdots \\ \phi(s_M)^\top \end{bmatrix} \in \mathbb{R}^{M \times (P+1)}, \quad M := \prod_{n=1}^N I_n,$$

从而有

$$\text{vec}(f_{\boldsymbol{\beta}}(\mathcal{S})) = \mathbf{\Phi}(\mathcal{S})\boldsymbol{\beta}.$$

在带掩码观测情形下，只需保留对应于 Ω 中观测条目的行，即可得到后续用于系数估计的观测设计矩阵。

至此，后文构造 NTD-PL 所需的基本对象已经齐备：一方面， $\mathcal{T}(\mathcal{X}, \{\mathbf{A}^{(n)}\})$ 给出共享的 Tucker 潜在张量；另一方面， $f_{\boldsymbol{\beta}}(\cdot)$ 给出逐元素的参数化非线性链接。第四章将在此基础上正式给出 NTD-PL 的模型定义、性质与优化方法。

4 提出的方法

在保持 Tucker 低秩骨架的前提下，如何以受控方式引入高阶交互，并同时保持参数规模、可解释性与优化可实现性？为此，本章先给出 NTD-PL 的结构动机，再正式定义模型，随后概括其基本性质，并给出与当前实现一致的统一学习目标和优化框架。

4.1 设计动机：显式高阶交互

标准 Tucker 分解 $\mathcal{T}(\mathcal{X}, \{\mathbf{A}^{(n)}\})$ 以共享核心张量和各模因子矩阵构成多线性生成机制，其本质是在低秩潜在空间中通过连续模乘生成观测张量。该结构在压缩、恢复与表示学习中具有良好的参数效率与结构透明性，但它默认观测条目可以由多线性机制充分刻画。对于存在饱和响应、非线性观测、复杂高阶耦合或曲面结构的数据，仅依赖多线性假设往往会带来系统性失配。

在矩阵情形中，一个自然的增强思路是从线性映射

$$\mathbf{y} = \mathbf{A}\mathbf{x} \quad (1)$$

推广到带有二次交互的映射


$$\mathbf{y} = \mathbf{A}\mathbf{x} + \mathcal{A}(\mathbf{x}, \mathbf{x}). \quad (2)$$

QMF^[13] 的核心启发正是：二次项的意义不在于单纯增参，而在于它提供了从局部平坦表示走向局部曲面表示的最基本一步。沿着同样的思路，对于张量情形，一个自然问题是：既然 Tucker 已经是线性低秩模型在多模数据上的推广，能否进一步将显式高阶交互引入 Tucker 的生成机制？

为此本文把 p 阶交互写入 Tucker，一个自然的显式原型可写为

$$\hat{y}_{i_1 \dots i_N}^{(p)} = \sum_{\mathbf{r}^{(1)}, \dots, \mathbf{r}^{(p)}} \left(\prod_{q=1}^p x_{\mathbf{r}^{(q)}} \right) \prod_{n=1}^N a_{i_n, r_n^{(1)}, \dots, r_n^{(p)}}^{(n)}, \quad (3)$$

其中每个模因子在第 n 模上同时依赖 p 个潜在索引。式 (3) 定义了一种高次 Tucker 分解：它保留了逐模生成的 Tucker 外形，但把每一模的线性映射替换成了显式的 p 阶局部耦合。对于 $p = 2$ ，它对应二次 Tucker；一般 p 时，可视为一个显式 p 次 Tucker 原型，我们记为 p -Tucker。下图用张量网络更直观地展示这种 Tucker 的高次扩展。



这一原型虽然在概念上自然，却不适合作为最终模型。随着次数 p 增大，模因子需要提升为更高阶张量，核心张量在生成过程中也会诱导出 Kronecker 型高阶扩展，参数量、存储与收缩计算都会迅速膨胀。更重要的是，优化难度也会随之显著增加。因此，显式 p -Tucker 更适合作为结构动机：它解释了高阶交互进入 Tucker 的方式，却没有直接给出一个可扩展的实现。

基于这一观察，本文不直接训练式 (3) 所对应的显式高阶模型，而是寻找一种结构化压缩：既保留 p -Tucker 高阶交互的语义，又保持 Tucker 的参数量。NTD-PL 正是这一设计目标下得到的模型。

4.2 NTD-PL 模型定义与结构解释

4.2.1 模型定义

本文提出多项式链接的非线性 Tucker 分解 NTD-PL。其核心思想是：先用 Tucker 分解生成一个共享的低秩潜在张量，再在该潜在张量上施加显式的逐元素多项式链接。具体而言，记

$$\mathcal{S} = \mathcal{T}(\mathcal{X}, \{\mathbf{A}^{(n)}\}), \quad (4)$$

其中 $\mathcal{X} \in \mathbb{R}^{R_1 \times \dots \times R_N}$ 为核心张量， $\mathbf{A}^{(n)} \in \mathbb{R}^{I_n \times R_n}$ 为第 n 模因子矩阵。NTD-PL 定义为

$$\hat{\mathcal{Y}} = f_{\beta}(\mathcal{S}) = \sum_{p=0}^P \beta_p \mathcal{S}^{\odot p}, \quad (5)$$

其中 $\beta = (\beta_0, \beta_1, \dots, \beta_P)^\top$ 为多项式链接系数， $\mathcal{S}^{\odot p}$ 表示 $\mathcal{S}$ 的逐元素 p 次幂。

式 (5) 中， β_0 对应常数偏置项， β_1 对应标准 Tucker 线性项，而 β_p ($p \geq 2$) 则对应在共享低秩骨架上激活的高阶交互项。特别地，当

$$\beta_1 = 1, \quad \beta_p = 0 \ (p \neq 1) \quad (6)$$

时，模型精确退化为标准 Tucker。因此，NTD-PL 不是替代 Tucker 的另一类新骨架，而是以 Tucker 潜在张量为中心的受控非线性扩展。

NTD-PL 不能简单理解为先做一次 Tucker 重构，再对输出做逐元素校正。关键区别在于：式 (5) 中的非线性作用对象不是一个与低秩结构无关的外部信号，而是共享 Tucker 潜在张量 $\mathcal{S}$ 本身。由于 $\mathcal{S}$ 的每个条目已经由核心张量与各模因子的多线性耦合生成，因此 $\mathcal{S}^{\odot p}$ 对应的是同一骨架上交互模式的重组，而不是对一个已经完成的线性重构施加独立校准。后文将专门通过 Tucker 的多项式后处理与 NTD-PL 的对比，区分这两种机制。

4.2.2 作为 p -Tucker 的结构化压缩

NTD-PL 的定义来源于对 p -Tucker 的一种结构化压缩。以二次情形为例，若将式 (3) 中的模因子写成

$$a_{i_n, r_n, r'_n}^{(n)} \approx b_{i_n, r_n}^{(n)} c_{i_n, r'_n}^{(n)}, \quad (7)$$

则二次项可重写为两个 Tucker 张量的逐元素乘积：

$$\hat{\mathcal{Y}}_2 \approx \mathcal{S}_B \odot \mathcal{S}_C, \quad (8)$$


其中

$$\mathcal{T}(\mathcal{X}, \{\mathbf{B}^{(n)}\}), \quad \mathcal{T}(\mathcal{X}, \{\mathbf{C}^{(n)}\}). \quad (9)$$

进一步施加共享投影约束 $\mathbf{B}^{(n)} = \mathbf{C}^{(n)}$ ，便得到

$$\hat{\mathcal{Y}}_2 \approx \mathcal{S}^{\odot 2}. \quad (10)$$

按同样思路推广到更高阶，就得到共享骨架上的 $\mathcal{S}^{\odot p}$ 。于是，NTD-PL 可被理解为将这些共享投影的 p 阶交互项按系数线性组合，从而把显式 p -Tucker 的复杂性压缩到少量链接系数中，下图用张量网络图直观地表示了这一行为。



4.3 NTD-PL 的基本性质

本节概括 NTD-PL 的三个最基本性质：模型族关系与参数效率、非线性生成下的表达能力，以及尺度不定性与归一化机制。详细证明见附录 A–B。之后我们会看到，这些性质在可控合成数据实验中得到验证。

4.3.1 模型族关系与参数效率

命题 1 (退化到 Tucker). 若 $\beta_1 = 1$, 且对所有 $p \neq 1$ 有 $\beta_p = 0$, 则式 (5) 退化为标准 *Tucker* 模型, 即

$$\hat{\mathcal{Y}} = \mathcal{S} = \mathcal{T}(\mathcal{X}, \{\mathbf{A}^{(n)}\}). \quad (11)$$

命题 2 (次数嵌套性). 对任意 $P_1 < P_2$, $\text{degree-}P_1$ 的 *NTD-PL* 模型类是 $\text{degree-}P_2$ 模型类的子集。

这两个命题说明, NTD-PL 构成了一族关于多项式次数 P 的嵌套模型: 当高阶项关闭时, 它精确回到 Tucker; 随着 P 增加, 模型表达力按次数受控扩张。这也是后文采用逐次延续优化的理论基础。

命题 3 (参数复杂度). 设多线性秩为 $(R_1, \dots, R_N)$, 则 *NTD-PL* 的参数总数为

$$\#\text{param} = \prod_{n=1}^N R_n + \sum_{n=1}^N I_n R_n + (P + 1), \quad (12)$$

其中前两项对应标准 *Tucker* 分解的核心与因子参数量, 最后一项对应多项式链接系数。

命题 3 表明, NTD-PL 的额外自由度只体现为 $P + 1$ 个标量系数, 而不是新的高阶因子张量或高阶核心。因而, 相比显式 p -Tucker, NTD-PL 不是通过增加另一套高阶参数化来增强表达力, 而是在基本保持 Tucker 参数规模一致的前提下引入受控非线性。

4.3.2 非线性生成下的表达能力

NTD-PL 的表达能力可以从逐元素非线性生成模型的角度理解。设存在某个真实 Tucker 潜在张量

$$\mathcal{S}^* = \mathcal{T}(\mathcal{X}^*, \{\mathbf{A}^{(n)*}\}) \quad (13)$$

并设观测张量由某个标量函数 $g: \mathbb{R} \rightarrow \mathbb{R}$ 逐元素作用生成, 即

$$\mathcal{Y} = g(\mathcal{S}^*). \quad (14)$$

命题 4 (多项式生成下的精确表达). 若观测张量满足 $\mathcal{Y} = g(\mathcal{S}^*)$, 其中 $g(s) = \sum_{p=0}^P a_p s^p$ 为次数不超过 P 的多项式, 则取潜在张量 $\mathcal{S} = \mathcal{S}^*$ 且 $\beta_p = a_p$ 时, *NTD-PL* 可精确表示该生成过程。详细证明见附录定理 2。

定理 1 (解析函数下的显式截断误差界). 设 g 在复圆盘

$$D(0, \rho) = \{z \in \mathbb{C} : |z| < \rho\} \quad (15)$$

内解析, 且存在常数 B 满足

$$\|\mathcal{S}^*\|_\infty \leq B < \rho. \quad (16)$$

记 g 在 0 点的 *Taylor* 展开为

$$g(s) = \sum_{p=0}^{\infty} a_p s^p, \quad (17)$$

并记其 P 阶截断多项式为

$$q_P(s) = \sum_{p=0}^P a_p s^p. \quad (18)$$

若取 *NTD-PL* 的潜在张量为 $\mathcal{S}^*$, 并令链接系数满足 $\beta_p = a_p$, 则其逼近误差满足

$$\|g(\mathcal{S}^*) - q_P(\mathcal{S}^*)\|_F \leq \sqrt{N_e} M_\rho \frac{(B/\rho)^{P+1}}{1 - B/\rho}, \quad (19)$$

其中

$$N_e = \prod_{n=1}^N I_n, \quad M_\rho = \sup_{|z|=\rho} |g(z)|. \quad (20)$$

式 (19) 给出了一个具有明确解释性的误差分解。首先, 主导项 $(B/\rho)^{P+1}$ 表明, 当 $B/\rho < 1$ 固定时, 截断误差会随多项式阶数 P 以几何速度衰减, 因此只要真实潜在张量的幅值范围没有逼近解析半径边界, 有限阶 *NTD-PL* 就能够快速逼近解析生成函数。其次, 分母项 $1 - B/\rho$ 刻画了“距离奇点的裕量”: 当 B 相对 ρ 更小时, 说明真实信号活动区间位于更稳定的解析区域内部, 此时余项界更紧; 反之, 当 B 逐渐接近 ρ 时, 逼近难度会显著上升。最后, $\sqrt{N_e}$ 只反映从标量一致逼近推广到整张量 *Frobenius* 误差时的规模放大, 而不改变误差关于 P 的收敛阶。因而, 该定理说明 *NTD-PL* 的逼近能力主要由链接函数在有效输入区间上的解析性以及 B/ρ 的相对大小决定, 而不是由额外高阶张量参数的引入所驱动。这些将会解释第 5.2.2 节中的逼近的现象。

4.3.3 尺度不定性与归一化机制

与标准 *Tucker* 一样, *NTD-PL* 继承了核心张量与因子矩阵之间的尺度不定性。由于 *NTD-PL* 同时组合 $\mathcal{S}, \mathcal{S}^{\odot 2}, \dots, \mathcal{S}^{\odot P}$, 这一尺度问题在多项式链接中更加敏感: 若 $\mathcal{S}$ 的尺度漂移, 不同阶次项会按不同速率放大或缩小, 进而直接影响 β 的数值稳定性。

命题 5 (尺度不变性). 设对某一模 n 的因子矩阵施加可逆对角缩放 $D^{(n)}$, 并同时将对逆缩放吸收到核心张量中, 则潜在张量 $\mathcal{S}$ 保持不变, 从而 *NTD-PL* 的输出 $\hat{\mathcal{Y}} = f_\beta(\mathcal{S})$ 也保持不变。

命题 5 说明, 因子列归一化并将尺度吸收到核心张量中, 可以理解为一种 *gauge fixing*: 它不改变模型能力, 只从等价参数化中选取更稳定的表示。在高阶项参与建模时, 这一步对 β 的估计尤为重要, 因此后文优化算法中将其作为固定步骤。

4.4 统一学习目标与优化算法

4.4.1 统一学习目标

为在同一优化框架下同时处理分解与缺失补全, 记二值观测掩码张量为 $\Omega \in \{0, 1\}^{I_1 \times \dots \times I_N}$ 。考虑如下目标函数:

$$\min_{\mathcal{X}, \{\mathbf{A}^{(n)}\}, \beta} \frac{1}{2Z_\Omega} \|\Omega \odot (\mathcal{Y} - f_\beta(\mathcal{S}))\|_F^2 + \mathcal{R}(\mathcal{X}, \{\mathbf{A}^{(n)}\}, \beta), \quad (21)$$

其中 $\mathcal{S} = \mathcal{T}(\mathcal{X}, \{\mathbf{A}^{(n)}\})$, 且

$$Z_{\Omega} = \begin{cases} \prod_{n=1}^N I_n, & \Omega \equiv \mathbf{1}, \\ \sum_{i_1, \dots, i_N} \Omega_{i_1 \dots i_N}, & \text{否则}. \end{cases} \quad (22)$$

这里的 Z_{Ω} 用于按有效条目数归一化数据拟合项, 使完整观测与缺失观测两种情形下的梯度量级保持可比; 这也与当前实现中的残差缩放方式一致。正则项取为

$$\mathcal{R}(\mathcal{X}, \{\mathbf{A}^{(n)}\}, \boldsymbol{\beta}) = \frac{\lambda_X}{2} \|\mathcal{X}\|_F^2 + \sum_{n=1}^N \frac{\lambda_n}{2} \|\mathbf{A}^{(n)}\|_F^2 + \frac{\lambda_{\beta}}{2} \|\boldsymbol{\beta}\|_2^2. \quad (23)$$

当 $\Omega \equiv \mathbf{1}$ 时, 式 (21) 就是完整张量上的 NTD-PL 分解; 当 Ω 为一般掩码时, 它对应仅在观测位置上训练的补全目标。由此, 分解与补全不再需要两套不同模型, 只是同一学习目标下的不同观测设置。

4.4.2 初始化

NTD-PL 是 Tucker 的多项式推广, 自然可以利用 Tucker 分解作为优化起点。对完整观测使用标准 Tucker 初始化, 对缺失观测使用 masked Tucker 初始化^[26-27]。对多项式系数, 采用线性 warm start:

$$\beta_0 = 0, \quad \beta_1 = 1, \quad \beta_p = 0 \quad (p \geq 2). \quad (24)$$

本文采用逐次延续的优化方式, 从 $p = 1$ 的线性情形开始, 随着优化推进再逐步激活更高阶项, 意味着模型总是从标准 Tucker 解附近出发, 而不是从一个高阶非线性模型直接起步。

4.4.3 核心与因子的更新

固定 $\boldsymbol{\beta}$ 后, 首先构造潜在张量

$$\mathcal{S} = \llbracket \mathcal{X}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket, \quad (25)$$

并计算预测张量

$$\hat{\mathcal{Y}} = f_{\boldsymbol{\beta}}(\mathcal{S}), \quad f'_{\boldsymbol{\beta}}(\mathcal{S}) = \sum_{p=1}^P p \beta_p \mathcal{S}^{\odot(p-1)}. \quad (26)$$

在当前实现中, $f_{\boldsymbol{\beta}}(\mathcal{S})$ 与 $f'_{\boldsymbol{\beta}}(\mathcal{S})$ 通过一次融合的 Horner 递推同时求值, 以减少重复的幂次计算与内存访问; 这只改变常数开销, 不改变模型本身。

记归一化后的掩码残差为

$$\mathbf{E} = \frac{1}{Z_{\Omega}} \Omega \odot (\hat{\mathcal{Y}} - \mathcal{Y}), \quad (27)$$

并记

$$\mathbf{T} = \mathbf{E} \odot f'_{\boldsymbol{\beta}}(\mathcal{S}). \quad (28)$$

则根据链式法则, 目标函数对潜在张量 $\mathcal{S}$ 的梯度正比于 $\mathbf{T}$ 。进一步通过 Tucker 重构关系反向传播, 可得核心张量梯度

$$\nabla_{\mathcal{X}} \mathcal{L} = \mathbf{T} \times_1 \mathbf{A}^{(1)\top} \times_2 \dots \times_N \mathbf{A}^{(N)\top} + \lambda_X \mathcal{X}. \quad (29)$$

对于第 n 模因子矩阵, 记

$$\mathbf{Z}^{(n)} = \left[\mathcal{X} \times_{m \neq n} \mathbf{A}^{(m)} \right]_{(n)}, \quad (30)$$

其中 $[\cdot]_{(n)}$ 表示模 n 展开, 则相应梯度可写为

$$\nabla_{\mathbf{A}^{(n)}} \mathcal{L} = \mathbf{T}_{(n)} \mathbf{Z}^{(n)\top} + \lambda_n \mathbf{A}^{(n)}. \quad (31)$$

由于逐元素多项式链接打破了经典 Tucker 中最小二乘子问题的闭式结构, 本文不采用交替最小二乘法, 而是使用 Adam^[28] 对 $\mathcal{X}$ 与各模因子做梯度更新。

4.4.4 多项式系数的更新

固定 $\mathcal{X}$ 与 $\{\mathbf{A}^{(n)}\}_{n=1}^N$ 时, 潜在张量 $\mathcal{S}$ 也随之固定, 此时 β 的更新可归结为一个低维 ridge 回归问题^[29]. 记观测向量为 $\mathbf{y}_\Omega$, 并定义设计矩阵

$$\Phi_\Omega = [\mathbf{1}, \text{vec}(\mathcal{S})_\Omega, \text{vec}(\mathcal{S}^{\odot 2})_\Omega, \dots, \text{vec}(\mathcal{S}^{\odot P})_\Omega] \in \mathbb{R}^{|\Omega| \times (P+1)}. \quad (32)$$

则 β 子问题为

$$\min_{\beta} \frac{1}{2} \|\mathbf{y}_\Omega - \Phi_\Omega \beta\|_2^2 + \frac{\lambda_\beta}{2} \|\beta\|_2^2. \quad (33)$$

若允许常数项参与拟合, 则直接求解式 (33); 若不允许多项式项, 则固定 $\beta_0 = 0$, 仅对 $p \geq 1$ 的系数做相同的 ridge 更新. 由于 $\lambda_\beta > 0$, 系统矩阵 $\Phi_\Omega^\top \Phi_\Omega + \lambda_\beta I$ 始终正定, 因此该子问题强凸且存在唯一解. 其严格证明见附录 C.1.

尽管整体问题对 $(\mathcal{X}, \{\mathbf{A}^{(n)}\}, \beta)$ 联合来看是非凸的, 但在固定 Tucker 潜变量 $\mathcal{S}$ 后, 对 β 的更新始终是一个规模仅为 $P+1$ 的强凸 ridge 回归. 这也是本文能够在保持高阶非线性表达的同时, 仍使用稳定交替优化框架的关键原因.

高阶幂基在数值上可能病态, 尤其当 $\mathcal{S}$ 的取值范围较大时更为明显. 为改善这一问题, 优化实现中可先在标准化变量

$$\mathbf{z} = \frac{\mathcal{S} - \mu}{\sigma} \quad (34)$$

的幂基上求解系数 γ , 再通过基变换将其映回原始幂基系数 β . 这一过程只改变子问题求解的数值条件, 并不改变外层模型的形式.

4.4.5 因子归一化与核心吸收

在每轮梯度更新后, 本文对每个因子矩阵的列向量做单位 ℓ_2 范数归一化, 并将对应尺度吸收到核心张量中. 根据命题 5, 该步骤不会改变潜在张量 $\mathcal{S}$, 因此也不会改变 NTD-PL 的输出. 其作用在于减少等价参数化引入的尺度漂移, 特别是降低 $\mathcal{S}$ 的尺度变化对高阶项 $\mathcal{S}^{\odot p}$ 和 β 估计带来的耦合影响.

4.4.6 次数延续策略

直接从零开始优化高阶多项式模型通常不够稳定. 为此, 本文采用次数延续 (degree continuation) 策略: 训练从 $p=1$ 的线性 Tucker 情形开始, 并在预设里程碑 $\tau_2 < \dots < \tau_P$ 处逐步激活更高阶项. 每当第 p 阶项被激活时, 对应的新系数初始化为零, 即

$$\beta^{\text{new}} = (\beta_0, \dots, \beta_{p-1}, 0)^\top. \quad (35)$$

这样, 模型便可从稳定的线性解逐步过渡到更丰富的非线性解, 而不是一开始就在高阶搜索空间中联合优化全部系数. 命题 2 已说明, 这样的 continuation 不是经验性“技巧”, 而是顺应模型族嵌套结构的自然优化路径.

4.4.7 算法复杂度分析

记观测张量总元素个数为

$$M = \prod_{n=1}^N I_n, \quad M_\Omega = |\Omega|, \quad R = \prod_{n=1}^N R_n. \quad (36)$$

这里 M 表示完整张量的条目总数, M_Ω 表示观测条目数.

Algorithm 1 基于交替优化与次数延续的 NTD-PL

```

1: 输入: 观测张量  $\mathcal{Y}$ 、掩码  $\Omega$ 、多线性秩  $\{R_n\}$ 、最大多项式次数  $P$ 
2: 通过 Tucker / masked Tucker 初始化  $(\mathcal{X}, \{\mathbf{A}^{(n)}\})$ 
3: 初始化  $\beta_0 = 0, \beta_1 = 1, \beta_p = 0 \ (p \geq 2)$ 
4: 若启用 continuation, 则当前次数置为  $p \leftarrow 1$ ; 否则置为  $p \leftarrow P$ 
5: for  $t = 1, 2, \dots, T$  do
6:   若到达新的次数里程碑, 则激活下一阶项并将新系数置零
7:   构造潜在张量  $\mathcal{S} = \llbracket \mathcal{X}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket$ 
8:   计算  $f_\beta(\mathcal{S})$  与  $f'_\beta(\mathcal{S})$ , 得到残差张量与中间量  $\mathbf{T}$ 
9:   用 Adam 更新核心张量  $\mathcal{X}$  与各模因子  $\{\mathbf{A}^{(n)}\}$ 
10:  对因子列归一化, 并将尺度吸收到核心张量中
11:  if  $t$  满足  $\beta$  更新间隔 then
12:    固定当前  $\mathcal{S}$ , 通过 ridge 回归更新  $\beta$ 
13:  end if
14: end for
15: 输出:  $\mathcal{X}$ 、 $\{\mathbf{A}^{(n)}\}$  与  $\beta$ 

```

做一次标准 Tucker 重构时, 若按逐模乘法顺序实现, 其前向复杂度可写为

$$\mathcal{C}_{\text{rec}} = \sum_{n=1}^N I_n R_n \left(\prod_{m < n} I_m \right) \left(\prod_{m > n} R_m \right). \quad (37)$$

该项给出潜在张量 $\mathcal{S}$ 的主要构造代价, 也是后续梯度传播的基础。

给定 $\mathcal{S}$ 后, 计算 $f_\beta(\mathcal{S})$ 与 $f'_\beta(\mathcal{S})$ 的代价均为逐元素多项式求值。若采用融合的 Horner 递推, 则它们可在一次遍历中同时完成, 渐近复杂度为

$$\mathcal{O}(PM). \quad (38)$$

相较于分别计算前向值与导数, 这一融合实现仅降低常数因子, 不改变关于 P 与 M 的阶数。

核心梯度的计算可视为把张量 $\mathbf{T}$ 重新投影回核心空间, 其复杂度与一次 Tucker 压缩同阶。因子梯度的计算则具有 MTTKRP 型结构: 对每个模 n , 需要先构造式 (30) 中的 $\mathbf{Z}^{(n)}$, 再计算 $\mathbf{T}_{(n)}\mathbf{Z}^{(n)\top}$ 。因此, 若每轮外迭代对 $(\mathcal{X}, \{\mathbf{A}^{(n)}\})$ 执行 K 步 Adam 更新, 则其主导成本可近似写为

$$\mathcal{O}(K(\mathcal{C}_{\text{rec}} + PM + \mathcal{C}_{\text{bwd}})), \quad (39)$$

其中 $\mathcal{C}_{\text{bwd}}$ 代表由核心反投影与各模因子 MTTKRP 型乘法构成的反向传播成本, 通常与 Tucker 骨架本身的收缩/展开复杂度同阶。

在固定 $\mathcal{S}$ 时, β 子问题只依赖观测条目。构造观测设计矩阵 $\Phi_\Omega \in \mathbb{R}^{M_\Omega \times (P+1)}$ 的代价为

$$\mathcal{O}(PM_\Omega), \quad (40)$$

求解正规方程

$$(\Phi_\Omega^\top \Phi_\Omega + \lambda_\beta I) \boldsymbol{\beta} = \Phi_\Omega^\top \mathbf{y}_\Omega \quad (41)$$

的代价为

$$\mathcal{O}(M_\Omega P^2 + P^3). \quad (42)$$

由于 P 在本文设置中通常很小 (如 2, 3, 4), 因此 β 更新虽然理论上是额外步骤, 但在总体时间中通常并非主导项。

因子归一化与核心吸收的代价为

$$\mathcal{O}\left(\sum_{n=1}^N I_n R_n + R\right), \quad (43)$$

相较于式 (39) 通常可以忽略。次数延续不会改变单轮迭代的渐近复杂度，只会通过逐步激活高阶项影响总迭代轮数。优化实现中，避免重复 Tucker 重构、融合多项式/导数求值、以及在标准化幂基上稳定求解 β ，都只降低常数开销或改善数值条件，不改变上述渐近阶数。

综合上述各项，当前稠密实现下 NTD-PL 的单轮外迭代复杂度可概括为

$$\mathcal{O}(K(\mathcal{C}_{\text{rec}} + PM + \mathcal{C}_{\text{bwd}}) + PM_{\Omega} + M_{\Omega}P^2 + P^3). \quad (44)$$

因此，NTD-PL 相比标准 Tucker 的额外计算主要来自两部分：其一是逐元素多项式链接及其导数的计算，其代价为低阶、可并行的 $\mathcal{O}(PM)$ ；其二是 β 的小规模 ridge 更新，其代价为 $\mathcal{O}(PM_{\Omega} + M_{\Omega}P^2 + P^3)$ 。换言之，当前实现下的主导成本仍然来自 Tucker 骨架本身的前向/反向传播，而不是多项式链接系数的求解。

5 实验

本章在统一协议下报告 NTD-PL 在合成与真实高光谱数据上的实验结果。实验依次包括共享设置、可控合成数据、以及真实高光谱上的恢复与补全，用于说明方法的适用范围、收益来源和计算代价。

5.1 实验设置

本节给出后续实验共享的数据生成原则、比较口径与评价指标。除各小节特有的实现细节外，所有结果均遵循同一套可复现实验协议。

为统一定义不同非线性映射下的非线性强度，本文将 α 定义为正交非线性残差的能量占比，而不是直接乘在非线性函数前的幅值系数。设线性低秩骨架为

$$\mathcal{S}^* \in \mathbb{R}^{I_1 \times \cdots \times I_N}, \quad (45)$$

给定逐元素映射 $g(\cdot)$ 后，先构造相对 $\mathcal{S}^*$ 的正交残差

$$\mathcal{R}^* = g(\mathcal{S}^*) - \frac{\langle g(\mathcal{S}^*), \mathcal{S}^* \rangle}{\|\mathcal{S}^*\|_F^2} \mathcal{S}^*, \quad (46)$$

再归一化为

$$\tilde{\mathcal{R}}^* = \frac{\|\mathcal{S}^*\|_F}{\|\mathcal{R}^*\|_F} \mathcal{R}^*. \quad (47)$$

最终观测张量定义为

$$\mathcal{Y}_\alpha = \sqrt{1-\alpha} \mathcal{S}^* + \sqrt{\alpha} \tilde{\mathcal{R}}^*, \quad 0 \leq \alpha \leq 1. \quad (48)$$

因此， α 表示的是观测中分配给正交非线性残差的能量比例。随着 α 增大，观测会逐步偏离线性低秩骨架，而不是仅仅放大观测幅值。对于线性一致性小节中出现的仿射偏移控制，其本质是在线性 Tucker 源数据上加入常数偏置后再归一化。

可控合成实验考虑两类多项式残差族和两类平滑残差族：

$$g_{\text{poly2}}(s) = s^2, \quad g_{\text{poly3}}(s) = s^2 + s^3, \quad (49)$$

$$g_{\text{sin}}(s) = \sin(\kappa_{\text{sin}} s), \quad g_{\text{tanh}}(s) = \tanh(\kappa_{\text{tanh}} s). \quad (50)$$

其中 κ_{sin} 与 κ_{tanh} 根据输入尺度自适应设定，以避免函数长期停留在线性区间或过早饱和。

实验以 NMSE 和 RMSE 作为主指标。真实高光谱实验中，全观测重构统一报告 RMSE、NMSE 与 SAM；随机缺失补全优先报告 RMSE*、NMSE*、SAM*。其中带 * 的指标表示仅在确实观测上计算，是补全质量的主判断依据。

对于后文涉及的 β_p 项贡献百分比，本文统一采用

$$c_p = \frac{\|\beta_p \mathcal{S}^{\odot p}\|_F}{\sum_{q=0}^P \|\beta_q \mathcal{S}^{\odot q}\|_F} \times 100\%. \quad (51)$$

该定义刻画的是各阶项在整体展开中的相对强度分配， $\{c_p\}$ 对 p 求和后恰好等于 100%。

本文比较的线性低秩基线包括 Tucker、CP、TT 和 TR。Tucker 分解是本文最直接的线性参照。CP 分解将张量表示为若干秩一张量之和，具有更紧凑的参数化形式，也是低秩张量建模中最经典的基线之一^[8]。TT 分解采用链式核分解高阶张量，可显著降低高阶场景中的存储与计算复杂度^[30]。TR 分解进一步将链式结构闭合为环形，在秩分配上比 TT 更灵活^[31]。注意，各种分解的结构不同，秩的定义也不同，因此参数量无法做到完全一致，本文实验对比时选择的秩尽可能使参数量相近。

5.2 可控合成数据实验

本节在可控机制下比较线性基线与 NTD-PL。实验包含两部分：一是在线性源数据下比较 Tucker 与线性受限 NTD-PL 的配对误差，二是在统一非线性残差协议下比较不同方法随 α 和 P 的误差变化。

5.2.1 线性一致性验证

在线性源数据下，我们比较 Tucker 与 NTD-PL 的配对误差，以检验后者是否精确退化到 Tucker。具体地，数据为多个随机种子下生成的 Tucker 张量，秩为 $[4, 4, 4]$ ，加上仿射偏置 **bias**，然后进行能量归一化与 30 dB 噪声叠加；NTD-PL 取 $P = 6$ ，可选 β_0 是否引入。

表 1 显示，在 **bias**=0 时，Tucker 与不引入常数项的 NTD-PL 的拟合误差几乎完全重合，高次项贡献占比很低，证明 NTD-PL 线性一致；在 **bias**=0.5 时，NTD-PL 依然能较好地拟合，而 Tucker 和 β_0 受限的 NTD-PL 则出现系统性偏差。有趣的是，可以看到 NTD-PL 在 β_0 受限时自动通过高次项来拟合偏置，结果仍然略优于 Tucker。进一步地，配对差值分布图见附录图 11，其中也可以更直观地看到：当不存在仿射偏置时，Tucker 与 NTD-PL 的差异集中在零附近；而在存在偏置时，受限模型与 Tucker 之间会出现更明显的系统性配对间隙。

表 1: 比较纯线性源数据上的 Tucker 和 NTD-PL，用于检验 NTD-PL 的线性一致性

Setting	Method	RMSE	NMSE(dB)	$p > 1$ contrib. (%)
bias=0	Tucker	0.011398 ± 0.000747	-38.8822 ± 0.5704	—
	NTD-PL ($\beta_0 = 0$)	0.011610 ± 0.000658	-38.7173 ± 0.4883	4.19 ± 2.80
	NTD-PL (β_0 free)	0.011698 ± 0.000634	-38.6500 ± 0.4650	3.19 ± 2.15
bias=0.5	Tucker	0.064650 ± 0.016502	-24.0505 ± 2.0996	—
	NTD-PL ($\beta_0 = 0$)	0.052204 ± 0.011788	-25.8466 ± 1.8304	39.17 ± 11.56
	NTD-PL (β_0 free)	0.011797 ± 0.000596	-38.5755 ± 0.4319	2.98 ± 2.00

5.2.2 非线性映射匹配与逼近实验

在统一的非线性生成协议下 (见 5.1)，我们考虑多项式和广义非线性两种情形。具体地，数据由多个随机种子下生成的 Tucker 张量出发，分别施加 **poly2**、**poly3**、**sin** 与 **tanh** 四类逐元素非线性残差，并按式 (48) 控制非线性能量占比 α 。实验统一扫描 $\alpha \in \{0.10, 0.15, 0.20, 0.25, 0.30, 0.35, 0.40\}$ 与 $P \in \{1, 2, 3, 4, 5, 6\}$ ，并在 10 个随机种子上比较相近参数量下，Tucker、CP、TT、TR 与 NTD-PL 的 NMSE 表现。

图 1 表明，在各类非线性残差下，NTD-PL 在整个非线性强度区间内保持稳定领先，说明 NTD-PL 在处理非线性残差时具有优势。另外，可以看到 NTD-PL 的逼近误差随 α 缩放，结果趋势与推论 2 (见附录) 相符合：在本文的生成协议下，非线性残差的能量占比越高，有限阶多项式链接需要吸收的正交残差也越大，因此误差曲线会随 α 增大而整体抬升，但 NTD-PL 相对线性基线的优势仍能保持。

表 2: NTD-PL 各次数项的贡献 (单位: %)

nonlinear($\alpha = 0.25$)	β_0	β_1	β_2	β_3	β_4	β_5	β_6
poly2	0.5 ± 0.8	43.3 ± 17.5	23.2 ± 6.9	5.8 ± 4.9	8.2 ± 5.8	9.1 ± 9.5	9.8 ± 9.7
poly3	0.1 ± 0.1	24.1 ± 6.5	9.8 ± 4.1	38.1 ± 9.0	7.3 ± 5.5	11.5 ± 11.1	9.1 ± 6.3
sin	0.1 ± 0.1	37.7 ± 8.8	0.6 ± 0.6	35.4 ± 3.5	2.8 ± 2.7	19.8 ± 6.9	3.6 ± 3.8
tanh	0.2 ± 0.1	37.9 ± 9.0	1.3 ± 0.7	30.9 ± 4.0	5.4 ± 3.7	17.3 ± 3.5	7.0 ± 5.8




图 1: 可控非线性残差实验中, 不同方法的 NMSE 随非线性强度 α 的变化。四个 panel 分别对应 poly2、poly3、sin 与 tanh, 整体显示 NTD-PL 在各强度区间内保持稳定优势。

图 2 清晰地展示了不同次数 P 下的 NTD-PL 的拟合效果, 其中灰色水平线表示 Tucker 基线。可以看到, $P = 1$ 时的性能与 Tucker 相近, 又一次说明了 NTD-PL 的线性一致性, 随着多项式次数 P 的增加, NTD-PL 的性能逐渐优于 Tucker 基线。该结果表明, NTD-PL 确实能够逐步吸收非线性残差。进一步地, 性能提升主要集中在较低到中等阶数范围内, 而在更高阶时增益趋于饱和, 这与定理 1 的结论一致: 当真实链接函数为解析函数时, 有限阶截断误差主要由 $(B/\rho)^{P+1}$ 控制, 因此低阶到中阶时往往已经获得主要收益, 而继续提高 P 只会带来递减的边际改进。对于 poly2 和 poly3, NTD-PL 均在对应次数 ($P = 2$ 和 $P = 3$) 时出现系统性匹配, 这正是命题 4 在实验中的直接体现。一个有意思的现象是, 性能提升并非随次数增加而均匀出现。对于 sin 和 tanh, 明显的改进主要发生在奇数阶提升处, 而相邻偶数阶带来的额外收益较弱。考虑到这两类链路都具有奇对称性, 这一现象说明, 在当前近似零中心的实验协议下, 新增的有效表达能力更可能集中在奇次项上, 也说明理论上的“逐阶逼近”在具体实验中会受到真实函数主导项结构的影响。图 3 进一步展示了 NTD-PL 逐次增加的策略下的训练损失曲线, 可以看到次数增加的时刻往往伴随阶跃式的增益; 若从局部响应几何的角度理解这一过程, 附录图 12 给出了固定局部 Tucker patch 下不同 P 所诱导的响应图与偏差图, 可以更直观地看到新增阶次如何逐步改变局部非线性响应形状。




图 2: 固定非线性强度下, NTD-PL 的逼近误差随多项式最高阶数 P 的变化, 并与 Tucker 对照; 图中的灰色水平线表示 Tucker 基线。图中显示 $P=1$ 与 Tucker 接近 (线性一致性), 随后随 P 增大误差下降且边际收益逐步趋于饱和。




图 3: NTD-PL 在逐次增阶训练策略下的损失演化曲线。虚线对应阶数切换时刻, 可见多数场景在增阶后出现阶段性下降, 说明新增阶次能够吸收此前未建模的非线性残差。

5.3 高光谱数据上的非线性低秩重构与补全

本节转向真实高光谱数据上的实验验证，重点回答三个问题：第一，NTD-PL 相对线性 Tucker 的整体收益是否在真实场景中依然成立；第二，这种收益究竟来自哪里；第三，这一优势是否具有明确的空间定位、阶数机制和跨数据集稳定性。围绕这三个问题，后文依次从全观测重构、随机缺失补全、机制区分、局部收益定位、阶数饱和分析以及跨数据集鲁棒性六个方面展开，从而形成一条由整体性能、机制解释到外部验证的完整证据链。

5.3.1 数据与协议

实验分为主机分析分析与外部鲁棒性验证两层。主实验采用 CAVE^[32-33] 数据集中的 15 个场景，用于系统分析 NTD-PL 在真实高光谱张量上的整体收益、局部收益分布以及阶数机制；外部验证则进一步采用 Jasper Ridge^[34]、Samson^[35]、Urban^[36] 和 Cuprite^[37] 四个常用基线场景，用于检验主结论在不同空间尺寸、波段数和场景属性下是否仍然成立。

所有真实数据实验均采用全观测，保持原数据尺寸，不额外裁剪或降采样，也不对单个场景进行专门挑选。预处理方面，统一采用 global max normalization。评价指标沿用第 5.1 节：全观测重构报告 RMSE、NMSE(dB) 与 SAM；随机缺失补全则以仅在缺失项上计算的 RMSE*、NMSE(dB)* 与 SAM* 作为主指标。对于补全实验，Tucker 与 NTD-PL 在同一场景、同一缺失率和同一随机种子下共享观测掩膜，以保证配对比较的公平性。

参数方面，CAVE 全观测重构在正文中报告三组秩预算 (24, 24, 4)、(33, 33, 4) 和 (40, 40, 5)，用于观察不同压缩水平下的稳定趋势；CAVE 随机缺失补全则统一考察 $\rho = 0.1, 0.3, 0.5, 0.7$ 四个缺失率，并在相同秩与相同训练协议下比较 Tucker 与 NTD-PL。后续的机制区分、hard-pixel / boundary-region 分析以及阶数机制分析，都建立在这一统一补全协议之上，以避免由于任务设置变化而引入额外干扰。

跨数据集鲁棒性验证不再沿用单一固定秩，而是以统一压缩率匹配规则为每个数据集自动确定一组秩。对于这些补充数据集，补全任务统一固定随机逐元素缺失率 $\rho = 0.5$ 。因此，正文中的跨数据集比较并不是针对某个数据集单独调参后的最优结果，而是在统一协议下对不同真实场景进行的外部有效性检验。

5.3.2 全观测重构

我们首先考察全观测设置下的低秩重构性能。表 3 汇报了三组参数预算下的场景均值结果。可以看到，在 (24, 24, 4)、(33, 33, 4) 和 (40, 40, 5) 三组设置中，NTD-PL 均比 Tucker 取得了更低的 RMSE、更低的 NMSE(dB) 以及更低的 SAM。该结果说明，在保持 Tucker 低秩骨架参数规模不变的前提下，由多项式链接带来的稳定收益。

表 3: CAVE 全观测低秩重构结果。三组 rank 下，NTD-PL 和 Tucker 同参数量的条件下，均取得更低的 RMSE、NMSE(dB) 和 SAM。

Rank	Method	Param.	RMSE↓	NMSE(dB)↓	SAM(°)↓
(24, 24, 4)	Tucker	27,004	0.0299 ± 0.0198	-17.610 ± 4.498	17.42 ± 7.42
	NTD-PL	27,011	0.0256 ± 0.0178	-19.058 ± 4.725	15.15 ± 6.40
(33, 33, 4)*	Tucker	38,272	0.0261 ± 0.0172	-18.801 ± 4.432	16.43 ± 7.22
	NTD-PL	38,279	0.0223 ± 0.0150	-20.125 ± 4.515	14.41 ± 6.30
(40, 40, 5)	Tucker	49,115	0.0217 ± 0.0161	-20.739 ± 5.089	12.65 ± 5.93
	NTD-PL	49,122	0.0192 ± 0.0135	-21.509 ± 4.540	11.85 ± 5.84

* Main report rank in Sec. 5.3.2.

从数值上看, 这种收益在不同预算下都较为一致。在较低预算 (24, 24, 4) 下, NTD-PL 已经将 RMSE 从 0.0299 降至 0.0256, 同时将 SAM 从 17.42° 降至 15.15° ; 在主报告设置 (33, 33, 4) 下, RMSE 进一步从 0.0261 降至 0.0223, SAM 从 16.43° 降至 14.41° ; 在更高预算 (40, 40, 5) 下, 这种优势仍然保持。也就是说, 即使线性 Tucker 的秩已经提高, 真实高光谱张量中仍然存在无法被纯多线性机制充分吸收的系统残差, 而 NTD-PL 能够在共享低秩骨架上进一步对其进行修正。

进一步地, 我们考察这种优势是否仅由少数场景驱动。表 4 与图 4 给出的场景级对比表明, 在 (33, 33, 4) 下, NTD-PL 在 14/15 个场景上改善了 RMSE, 在 14/15 个场景上改善了 NMSE(dB), 并在 13/15 个场景上改善了 SAM。图 4 中, 绝大多数场景上的配对连线都向 NTD-PL 更优的一侧偏移, 说明该优势并非由少数异常样本抬高均值, 而是在场景级上具有明显的一致性。这表明 NTD-PL 的收益更接近于对高光谱数据中普遍存在的非线性失配进行系统补偿。

表 4: CAVE 全观测重构的场景级对比。NTD-PL 在绝大多数场景上优于 Tucker, 说明整体增益并非由少数异常场景驱动。

Metric	Win/Loss/Tie	Median gain	Sign test p	Wilcoxon p
RMSE	14/1/0	0.0028	9.77×10^{-4}	1.22×10^{-4}
NMSE_dB	14/1/0	1.1727	9.77×10^{-4}	1.22×10^{-4}
SAM	13/2/0	1.6423	0.007	0.022




图 4: CAVE 全观测重构的场景级对比可视化。每条连线连接同一场景下 Tucker 与 NTD-PL 的结果; 整体上, 大多数场景都朝 NTD-PL 更优的一侧移动, 说明其优势在场景层面具有一致性。

空间可视化结果进一步支持这一判断。图 5 给出了三个代表性场景的 pseudo-RGB 重构、逐像素误差图以及误差下降图。可以看到, NTD-PL 的收益并不是均匀涂抹式的, 而是更集中地出现在结构边界、局部高频纹理和材料过渡区域。例如, 在 **beads** 场景中, 珠粒边缘与遮挡交界处的误差下降最为明显; 在 **cd** 场景中, 圆盘边缘、中心孔轮廓以及盘面干涉高光与暗部的过渡带误差下降尤为明显; 在 **feathers** 场景中, 羽毛细丝的高频纹理、羽片层叠交叠处及其与背景的边界区域误差下降最为突出。这说明 NTD-PL 的额外表达能力并非简单地改变整体亮度响应, 而是在空间上更有针对性地修正线性低秩模型难以拟合的局部结构。




图 5: CAFE 全观测重构的空间可视化。各行对应一个代表场景；展示原图、重构图、逐像素误差图以及误差下降图。最后一列中正值表示 NTD-PL 相对 Tucker 进一步降低了重构误差。

图 6 从谱线角度给出了相同结论。对所选代表性像素，Tucker 往往能够恢复总体趋势，但在峰值位置、谷值深度或局部转折处仍存在明显偏差；相比之下，NTD-PL 在这些位置通常更贴近真值。可以看到 NTD-PL 对局部谱形的修正不仅降低了 RMSE，也显著改善了谱角误差。这说明前述场景均值和空间误差图中的收益，确实对应于更合理的逐波段恢复，而不是仅由少数强度偏移造成的表面改进。




图 6: CAFE 全观测重构的代表性谱线对比。给出对应像素的真值谱线与重构谱线。标注中的 ΔRMSE 和 ΔSAM 表示相对 Tucker 的改进量。

综合来看，CAFE 上的全观测实验给出了一条较完整的证据链：第一，NTD-PL 在匹配的参数预算下稳定优于 Tucker；第二，这种优势在场景级层面具有广泛一致性；第三，收益在空间上主要体现为局部误差下降，在光谱上则体现为对关键谱形的更准确恢复。由此可以认为，真实高光谱数据中的确存在可由共享低秩骨架上的显式低阶非线性进一步吸收的残差结构，而这正是 NTD-PL 相对线性 Tucker 的主要收益来源。

5.3.3 随机观测补全

在随机缺失观测设置下，我们进一步考察 NTD-PL 在缺失位置恢复上的表现。表 5 给出了四个缺失率下的主结果。可以看到，在 $\rho = 0.1, 0.3, 0.5, 0.7$ 的全部设置中，NTD-PL 都持续优于 Tucker，RMSE* 和 SAM* 都得到明显改善。这说明 NTD-PL 的优势并不局限于低缺失率下的轻微修正，而是在从轻度缺失到高度缺失的整个区间内都保持稳定。尤其在最高缺失率 $\rho = 0.7$ 下，RMSE* 的改善幅度进一步增大，表明当可用观测更稀疏时，非线性对缺失位置恢复仍然具有明显作用。

表 5: CAVE 随机缺失补全的主结果。四个缺失率下 NTD-PL 均优于 Tucker，说明收益直接体现在缺失位置的恢复质量上。

ρ	Method	RMSE*	NMSE(dB)*	SAM*
0.1	Tucker	0.0263 $\pm$ 0.0179	-18.728 $\pm$ 4.581	11.82 $\pm$ 5.33
	NTD-PL	0.0229 $\pm$ 0.0158	-19.909 $\pm$ 4.683	8.36 $\pm$ 3.38
0.3	Tucker	0.0263 $\pm$ 0.0179	-18.707 $\pm$ 4.575	14.75 $\pm$ 6.33
	NTD-PL	0.0230 $\pm$ 0.0158	-19.864 $\pm$ 4.664	12.47 $\pm$ 5.06
0.5	Tucker	0.0264 $\pm$ 0.0179	-18.688 $\pm$ 4.582	15.56 $\pm$ 6.85
	NTD-PL	0.0230 $\pm$ 0.0158	-19.865 $\pm$ 4.691	13.48 $\pm$ 5.75
0.7	Tucker	0.0266 $\pm$ 0.0180	-18.614 $\pm$ 4.573	16.02 $\pm$ 7.21
	NTD-PL	0.0219 $\pm$ 0.0128	-20.043 $\pm$ 4.227	13.79 $\pm$ 5.43

进一步地，我们希望确认这种优势是否同时在逐场景和逐缺失率两个层面成立。表 6 显示，RMSE* 在四个缺失率下均有 14/15 个场景优于 Tucker；SAM* 的胜场数仍分别达到 14/15、13/15、13/15 和 12/15。与此同时，Wilcoxon 检验与 sign test 的 p 值在各缺失率下都保持显著。这说明补全中的优势并不是由少数场景或单一缺失率偶然造成的，而是在逐场景和逐缺失率上都具有稳定的一致性。

表 6: CAVE 随机缺失补全的场景级对比。各缺失率下统一采用 Tucker – NTD-PL 的差值定义，因此正值表示 NTD-PL 更优。结果表明，补全收益在不同缺失率下都具有显著的场景级一致性。

ρ	Metric	Win/Loss/Tie	Median gain	Sign test p	Wilcoxon p
0.1	RMSE*	14/1/0	0.0027	9.77×10^{-4}	1.22×10^{-4}
0.1	SAM*	14/1/0	2.9742	9.77×10^{-4}	8.54×10^{-4}
0.3	RMSE*	14/1/0	0.0027	9.77×10^{-4}	1.22×10^{-4}
0.3	SAM*	13/2/0	1.9194	0.007	0.004
0.5	RMSE*	14/1/0	0.0026	9.77×10^{-4}	1.22×10^{-4}
0.5	SAM*	13/2/0	1.6566	0.007	0.012
0.7	RMSE*	14/1/0	0.0027	9.77×10^{-4}	1.22×10^{-4}
0.7	SAM*	12/3/0	1.3394	0.035	0.048

为了进一步说明这种收益确实发生在缺失位置的恢复上，而不是整体平滑带来的表面改善，附录图 13 给出了两个代表性场景的补全可视化结果。综合来看，随机缺失补全实验进一步强化了前一小结的结论：第一，NTD-PL 的优势不仅体现在全观测重构中，也体现在真正的缺失恢复任务上；第二，这种优势在多个缺失率下都保持稳定，并且在 scene-wise 与 rate-wise 两个层面同时成立；第三，附录中的空间可视化表明收益确实发生在 missing 区域本身，而不是由 all-entry 指标中的已观测位置掩盖或放大。换言之，CAVE 上的补全实验说明，显式条目层多项式链接不仅能够改进低秩近似，还能够观测不完整时更有效地恢复真实高光谱结构。

5.3.4 多项式后处理的机制区分

前两小节已经表明，NTD-PL 在全观测重构与随机缺失补全中都稳定优于 Tucker。但一个仍需进一步回答的问题是：这种收益究竟来自什么？一种解释则是，NTD-PL 的优势也许并不需要联合建模，只要先得到 Tucker 重构，再对其输出施加一个逐元素多项式校准即可。为区分这些可能性，我们引入一个后处理基线 *PolyCal*。该方法先训练标准 Tucker，再在其输出上拟合一个共享的逐元素四阶多项式响应映射，从而在不改变低秩骨架的前提下对条目层响应进行后处理修正。

表 7 汇报了这一机制对照的主结果。可以看到，*PolyCal* 后处理相对 Tucker 只能带来有限的改善，而 NTD-PL 则展现出更显著的性能提升，说明简单的后处理并不能替代 NTD-PL 的多项式与低秩骨架的联合建模。

表 7: 机制对照主表。三种方法在全观测重构与 $\rho = 0.5$ 的随机缺失补全上进行比较。PolyCal 在 Tucker 输出后施加共享逐元素多项式校准，而 NTD-PL 则将非线性链接与低秩骨架联合建模。

Setting	Method	Param.	RMSE↓	SAM↓
Recon.	Tucker	38,272	0.02606 ± 0.01718	16.4329 ± 7.2207
	PolyCal	38,277	0.02557 ± 0.01661	15.4054 ± 6.3013
	NTD-PL	38,279	0.02234 ± 0.01497	14.4082 ± 6.3010
Compl.	Tucker	38,272	0.02637 ± 0.01791	15.5569 ± 6.8502
	PolyCal	38,277	0.02587 ± 0.01731	14.3420 ± 5.7617
	NTD-PL	38,277	0.02299 ± 0.01582	13.4841 ± 5.7459

图 7 以四个 panel 更直观地展示了这一点：无论是在全观测重构的 RMSE、SAM，还是在补全任务的 RMSE*、SAM* 上，三种方法都呈现出一致的关系。Tucker 到 PolyCal 的下降说明“后处理响应修正”确实有意义，而 PolyCal 到 NTD-PL 的继续下降则说明，真正关键的并不只是对输出做一个逐元素多项式拟合，而是让这种非线性链接在训练过程中与低秩骨架共同决定表示结构。




图 7: 机制区分主图。四个 panel 分别比较全观测重构的 RMSE、SAM 以及 $\rho = 0.5$ 补全的 RMSE*、SAM*。三种方法都呈现出一致改进关系，说明后处理只能部分逼近 NTD-PL 的收益，而无法替代其联合建模。

因此，这一小节给出的结论是明确的：第一，NTD-PL 的收益不能解释为增参；第二，PolyCal 虽然能够吸收一部分条目层响应偏差，但只能部分逼近 NTD-PL 的表现；第三，真正关键的是在训练过程中将显式非线性链接与共享低秩骨架联合建模，而不是在得到线性低秩结果之后再附加一个统一的后处理映射。这也从机制层面解释了为什么 NTD-PL 不应被理解为对 Tucker 输出的简单校准，而应被看作一种对 Tucker 条目生成机制的结构化扩展。

5.3.5 优势出现的位置

本节关注一个更具体的问题：NTD-PL 的额外收益究竟出现在图像的哪些位置。若其作用只是“全局平滑修正”，收益应近似均匀；若其作用是修正线性低秩模型最难拟合的局部结构，收益应集中在高难度区域和结构边界附近。

我们先为每个像素定义两个分数：困难分数（Tucker 在该像素缺失位置上的 RMSE*）与边界分数（空间梯度幅值在光谱维上的平均）。然后在每个场景内分别按这两个分数分成四个 quartiles，并在场景间汇总。图 8 的每个网格值均按 Tucker - NTD-PL 定义，故正值表示 NTD-PL 更优。可以直接看到：无论沿困难度方向还是沿边界度方向，平均增益都随分位上升而增强，说明收益并非均匀分布，而是更集中在“更难、边界更强”的区域。




图 8: NTD-PL 相对 Tucker 的局部收益在困难 quartile 与边界 quartile 上的二维分布，正值表示 NTD-PL 更优。可以看到，收益并非均匀分布，而是主要集中在困难与边界的交叉区域。

为了把图 8 的统计结果落实到具体空间位置，图 9 固定展示 cd 场景。四个 panel 从左到右依次为：原图、difficulty map、boundary map、missing-only error reduction map。difficulty map 橙色越亮表示越难；boundary map 蓝色越亮表示边界/纹理越强；第四列红色表示 NTD-PL 更优、蓝色表示 Tucker 更优。图中的白色轮廓表示 top difficulty 与 top boundary 的交集区域。从空间分布看，红色和橙色增益区域并非在整幅图像上均匀铺开，最显著的误差下降发生在既难又靠近边界的像素位置，即材料交界、细纹理和过渡带等线性低秩假设更易失配的区域。由此可以更直观地理解：NTD-PL 的优势不是全局平滑，而是对关键局部残差的定点修正。

5.3.6 多项式次数考察

为考察 NTD-PL 的收益主要由哪些阶次提供，我们在与前文相同的 CAVE 随机缺失补全设置下扫描多项式最高阶数 P ，并记录 missing-only 指标及各阶项的有效贡献。图 10 左图表明，随着 P 从 1




图 9: 代表性 cd 场景上的局部收益定位。四列依次为 pseudo-RGB 原图、difficulty map（橙色越亮表示越难）、boundary map（蓝色越亮表示边界越强）以及 missing-only error reduction map（红色表示 NTD-PL 更优，蓝色表示 Tucker 更优）。白色轮廓表示 top difficulty 与 top boundary 的交集。可以看到正增益主要集中在高难度与强边界同时出现的位置。

提升到 4，补全性能持续改善；但主要收益集中在低到中阶范围内，继续提高阶数后增益已明显减弱。右图进一步显示，模型贡献主要由二阶和三阶项承担：当 $P \geq 3$ 时，这两项始终占主导，而四阶项仅提供较小的边际修正。这说明，真实高光谱补全中的主要失配并不需要很高阶的自由度来刻画，低到中阶的显式非线性已经足以吸收大部分非线性残差。




图 10: CAVE 随机缺失补全中的阶数机制分析。左图给出缺失位置主指标随多项式最高阶数 P 的变化；右图给出不同 P 下各阶项的平均有效贡献。

5.3.7 跨数据集的鲁棒性验证

为了检验上述结论是否仅在 CAVE 上成立，我们进一步在 Jasper Ridge、Samson、Urban 和 Cuprite 上进行外部验证，并同时考察全观测重构与随机缺失补全。所有数据集均采用全场景设置、global max normalization，并按统一压缩率匹配规则自动确定秩；补全任务统一固定随机逐元素缺失率 $\rho = 0.5$ 。表 8 表明，NTD-PL 的优势并非 CAVE-specific。在 Jasper Ridge、Samson 和 Urban 上，无论重建还是补全，NTD-PL 均优于 Tucker，且 $\Delta\text{NMSE}(\text{dB})$ 与 ΔSAM 大多保持同方向改善。整体上，RMSE 口径下 8 个 dataset $\times$ task 组合中有 7 个为正收益，说明其优势在不同场景与任务上具有

较好的稳定性。Cuprite 则提供了一个清晰的边界案例：在该场景下，NTD-PL 的收益明显减弱，部分指标上 Tucker 略优。这说明当数据更接近经典线性混合、条目层非线性偏离较弱时，Tucker 已能解释主要结构，此时多项式链接只能带来有限的边际改进。因此，NTD-PL 的结论应理解为：它在多数真实高光谱场景中都能稳定改进 Tucker，但这种优势并非无条件成立，其有效性仍取决于数据中条目层非线性残差的强弱。

表 8: 跨数据集鲁棒性验证主表。Recon. 行中 Tucker / NTD-PL 为 RMSE, Compl. 行中 Tucker / NTD-PL 为 RMSE*; Gain(%), Δ NMSE(dB) 与 Δ SAM 统一按 Tucker – NTD-PL 定义, 因此正值表示 NTD-PL 更优。

Dataset	Task	Rank	Tucker	NTD-PL	Gain(%)	Δ NMSE(dB)	Δ SAM($^\circ$)
Jasper Ridge	Recon.	(11,11,43)	0.04623	0.04302	6.93	0.623	0.981
	Compl.	(11,11,43)	0.04710	0.04342	7.82	0.708	1.156
Samson	Recon.	(10,10,35)	0.02626	0.02417	7.95	0.719	0.057
	Compl.	(10,10,35)	0.02681	0.02444	8.86	0.806	0.310
Urban	Recon.	(43,43,47)	0.04444	0.04285	3.59	0.318	0.288
	Compl.	(43,43,47)	0.04538	0.04326	4.67	0.415	0.488
Cuprite	Recon.	(35,26,54)	0.01759	0.01770	-0.60	-0.052	-0.037
	Compl.	(35,26,54)	0.01791	0.01781	0.56	0.048	-0.004

6 结论

本文围绕一个核心问题展开：在尽量保留 Tucker 低秩骨架的前提下，如何以可控方式引入有效非线性。为此，我们提出了 NTD-PL。该方法以共享 Tucker 潜在张量作为结构主干，在条目层施加显式多项式链接，从而把非线性增强压缩到少量链接系数中。NTD-PL 更强调结构延续性、参数可控性与机制可解释性。

围绕这一建模思想，本文给出了从模型到实验的完整论证。理论上，NTD-PL 与标准 Tucker 构成清晰嵌套：线性特例可精确退化为 Tucker，次数增加形成受控扩张；在多项式生成情形下可实现精确匹配，在解析函数情形下可获得有限阶逼近并给出截断误差界。算法上，我们给出了统一的学习框架，可同时处理全观测分解与带掩码补全，并与实际实现保持一致。

实验结果支持了上述判断。在线性一致性实验中，受限 NTD-PL 与 Tucker 基本重合，说明模型不会在纯线性 regime 中制造伪增益；在可控非线性残差实验中，性能趋势与理论预期一致。真实高光谱实验进一步表明，在 CAVE 的全观测重构与随机缺失补全任务中，NTD-PL 在匹配参数预算下稳定优于 Tucker，且优势在 scene-wise 与 rate-wise 层面均具有一致性。

更重要的是，机制与空间证据解释了为什么有效。机制对照显示，Tucker 输出上的后处理多项式校准 (PolyCal) 只能部分逼近 NTD-PL，无法替代非线性链接与低秩骨架的联合建模。空间分析显示，收益并非全局均匀平滑，而主要集中在高难度且强边界的局部区域。阶数分析进一步表明，主要收益集中在低到中阶，边际增益随阶数上升逐步饱和，说明该方法的额外计算开销是可量化且有边界的。跨数据集结果也给出了清晰结论：NTD-PL 在多数真实场景中有效，但并非无条件成立。当数据更接近线性混合、条目层非线性偏离较弱时，其额外收益会明显减弱。

未来工作可沿三条路径推进：其一，研究更稳定或更灵活的显式链接族（如正交基或分段基）以改善高阶数值条件；其二，发展更高效的掩码感知训练与近似计算，提升大规模补全效率；其三，围绕可辨识性、泛化误差与阶数自适应选择开展更系统的理论分析。总体而言，NTD-PL 提供了一条可分析、可实现、可扩展的“增强 Tucker”路径，为结构化非线性低秩建模提供了可复用起点。

参考文献

- [1] KOLDA T G, BADER B W. Tensor Decompositions and Applications[J/OL]. SIAM Review, 2009, 51(3): 455-500. DOI: 10.1137/07070111X.
- [2] DE LATHAUWER L, DE MOOR B, VANDEWALLE J. A Multilinear Singular Value Decomposition[J/OL]. SIAM Journal on Matrix Analysis and Applications, 2000, 21(4): 1253-1278. DOI: 10.1137/S0895479896305696.
- [3] CICHOCKI A, MANDIC D P, PHAN A H, et al. Tensor Decompositions for Signal Processing Applications: From Two-way to Multiway Component Analysis[J/OL]. IEEE Signal Processing Magazine, 2015, 32(2): 145-163. DOI: 10.1109/MSP.2013.2297439.
- [4] SIDIROPOULOS N D, DE LATHAUWER L, FU X, et al. Tensor Decomposition for Signal Processing and Machine Learning[J/OL]. IEEE Transactions on Signal Processing, 2017, 65(13): 3551-3582. DOI: 10.1109/TSP.2017.2690524.
- [5] LIU J, MUSIALSKI P, WONKA P, et al. Tensor Completion for Estimating Missing Values in Visual Data[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2013, 35(1): 208-220. DOI: 10.1109/TPAMI.2012.39.
- [6] TUCKER L R. Some mathematical notes on three-mode factor analysis[J]. Psychometrika, 1966, 31(3): 279-311.
- [7] DE LATHAUWER L, DE MOOR B, VANDEWALLE J. A multilinear singular value decomposition[J]. SIAM journal on Matrix Analysis and Applications, 2000, 21(4): 1253-1278.
- [8] KOLDA T G, BADER B W. Tensor decompositions and applications[J]. SIAM review, 2009, 51(3): 455-500.
- [9] HONG D, KOLDA T G, DUERSCH J A. Generalized canonical polyadic tensor decomposition [J]. SIAM review, 2020, 62(1): 133-163.
- [10] XU Z, YAN F, et al. Infinite Tucker decomposition: Nonparametric Bayesian models for multiway data analysis[J]. arXiv preprint arXiv:1108.6296, 2011.
- [11] SARAGADAM V, BALESTRIERO R, VEERARAGHAVAN A, et al. DeepTensor: Low-rank tensor decomposition with deep network priors[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(12): 10337-10348.
- [12] VAROLGUNES U, ZHOU D, YU D, et al. NMTucker: Non-linear Matryoshka Tucker Decomposition for Financial Time Series Imputation[C]//Proceedings of the Fourth ACM International Conference on AI in Finance. 2023: 516-523.
- [13] ZHAI Z, CHEN H, SUN Q. Quadratic matrix factorization with applications to manifold learning [J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(9): 6384-6401.
- [14] SCHEIN A, ZHOU M, BLEI D, et al. Bayesian poisson tucker decomposition for learning the structure of international relations[C]//International Conference on Machine Learning. 2016: 2810-2819.
- [15] ZHE S, ZHANG K, WANG P, et al. Distributed flexible nonlinear tensor factorization[J]. Advances in neural information processing systems, 2016, 29.
- [16] PAN Z, WANG Z, ZHE S. Streaming nonlinear Bayesian tensor decomposition[C]//Conference on Uncertainty in Artificial Intelligence. 2020: 490-499.

- [17] WU X, SHI B, DONG Y, et al. Neural tensor factorization for temporal interaction learning[C]// Proceedings of the Twelfth ACM international conference on web search and data mining. 2019: 537-545.
- [18] LIU B, HE L, ZHE S, et al. DeepCP: Flexible nonlinear tensor decomposition[C]//NeurIPS Workshops: vol. 3. 2017.
- [19] AHN D, SAINI U S, PAPALEXAKIS E E, et al. Neural additive tensor decomposition for sparse tensors[C]//Proceedings of the 33rd ACM International Conference on Information and Knowledge Management. 2024: 14-23.
- [20] DERKACH D, RUIZ A, SUKNO F M. Tensor decomposition and non-linear manifold modeling for 3D head pose estimation[J]. International Journal of Computer Vision, 2019, 127(10): 1565-1585.
- [21] XU S, PENG J, JI T Y, et al. Stacked tucker decomposition with multi-nonlinear products for remote sensing imagery inpainting[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-13.
- [22] WANG D, ZHAO G, CHEN H, et al. Nonlinear tensor train format for deep neural network compression[J]. Neural Networks, 2021, 144: 320-333.
- [23] LIU H, DANIEL L, WONG N. Model reduction and simulation of nonlinear circuits via tensor decomposition[J]. IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems, 2015, 34(7): 1059-1069.
- [24] DENG J, LIU H, BATSELIER K, et al. STORM: a nonlinear model order reduction method via symmetric tensor decomposition[C]//2016 21st Asia and South Pacific design automation conference (ASP-DAC). 2016: 557-562.
- [25] SHI Z W, ZHENG Y B, ZHANG Y, et al. Multidimensional nonlinear transform-based tensor representation for high-dimensional image reconstruction[J]. Pattern Recognition, 2025, 168: 111734.
- [26] YANG L, FANG J, LI H, et al. An iterative reweighted method for tucker decomposition of incomplete tensors[J]. IEEE Transactions on Signal Processing, 2016, 64(18): 4817-4829.
- [27] LIU J, MUSIALSKI P, WONKA P, et al. Tensor completion for estimating missing values in visual data[J]. IEEE transactions on pattern analysis and machine intelligence, 2012, 35(1): 208-220.
- [28] KINGMA D P, BA J. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [29] HOERL A E, KENNARD R W. Ridge regression: Biased estimation for nonorthogonal problems [J]. Technometrics, 1970, 12(1): 55-67.
- [30] OSELEDETS I V. Tensor-Train Decomposition[J]. SIAM Journal on Scientific Computing, 2011, 33(5): 2295-2317.
- [31] ZHAO Q, ZHOU G, XIE S, et al. Tensor Ring Decomposition[J]. arXiv preprint arXiv:1606.05535, 2016.
- [32] Columbia CAVE Laboratory. Multispectral Image Database[Z]. <https://cave.cs.columbia.edu/repository/Multispectral>. Accessed: 2026-04-13.
- [33] YASUMA F, MITSUNAGA T, ISO D, et al. Generalized Assorted Pixel Camera: Postcapture Control of Resolution, Dynamic Range, and Spectrum[J/OL]. IEEE Transactions on Image Processing, 2010, 19(9): 2241-2253. DOI: 10.1109/TIP.2010.2046811.

- [34] ROBERTS D A, SMITH M O, ADAMS J B. Green Vegetation, Nonphotosynthetic Vegetation, and Soils in AVIRIS Data[J/OL]. *Remote Sensing of Environment*, 1993, 44(2–3): 255-269. DOI: 10.1016/0034-4257(93)90020-X.
- [35] DAVIS C O, KAVANAUGH M, LETELIER R, et al. Spatial and Spectral Resolution Considerations for Imaging Coastal Waters[C/OL]//*Proceedings of SPIE: Coastal Ocean Remote Sensing*: vol. 6680. 2007: 66800P. DOI: 10.1117/12.734288.
- [36] Geospatial Research Laboratory (U.S.) HyperCube Sample Data Set: HYDICE Sensor Imagery URBAN[Z]. <https://hdl.handle.net/11681/2925>. Dataset. 2015.
- [37] RESMINI R G, KAPPUS M E, ALDRICH W S, et al. Mineral Mapping with HYperspectral Digital Imagery Collection Experiment (HYDICE) Sensor Data at Cuprite, Nevada, U.S.A.[J/OL]. *International Journal of Remote Sensing*, 1997, 18(7): 1553-1570. DOI: 10.1080/014311697218278.

A NTD-PL 的基本模型性质

本节对应正文第 4.3 节, 集中给出 NTD-PL 在模型族关系、参数复杂度与尺度不定性方面的补充证明。正文中只保留结论与含义, 详细推导统一放在本附录。

A.1 退化到 Tucker 与嵌套模型族

命题 6 (退化到 Tucker). 若 $\beta_1 = 1$, 且对所有 $p \neq 1$ 有 $\beta_p = 0$, 则式 (5) 退化为标准 *Tucker* 模型, 即

$$\hat{\mathcal{Y}} = \mathcal{S} = \llbracket \mathcal{X}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket. \quad (52)$$

证明. 由 NTD-PL 的定义

$$\hat{\mathcal{Y}} = \sum_{p=0}^P \beta_p \mathcal{S}^{\odot p}, \quad (53)$$

当 $\beta_1 = 1$ 且 $\beta_p = 0$ ($p \neq 1$) 时, 上式化简为

$$\hat{\mathcal{Y}} = \mathcal{S}. \quad (54)$$

又由 $\mathcal{S} = \llbracket \mathcal{X}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket$, 故得到标准 Tucker 分解形式。□

命题 7 (次数嵌套性). 对任意 $P_1 < P_2$, *degree- P_1* 的 NTD-PL 模型类是 *degree- P_2* 模型类的子集。

证明. 任取一个 *degree- P_1* 的 NTD-PL 模型

$$\hat{\mathcal{Y}} = \sum_{p=0}^{P_1} \beta_p \mathcal{S}^{\odot p}. \quad (55)$$

将其视为 *degree- P_2* 模型时, 只需令

$$\beta_p = 0, \quad p = P_1 + 1, \dots, P_2, \quad (56)$$

即可得到完全相同的输出。因此, 任意 *degree- P_1* 模型都属于 *degree- P_2* 模型类。□

A.2 参数复杂度

命题 8 (参数复杂度). 设 *Tucker* 多线性秩为 $(R_1, \dots, R_N)$, 则 NTD-PL 的参数总数为

$$\#\text{param} = \prod_{n=1}^N R_n + \sum_{n=1}^N I_n R_n + (P + 1). \quad (57)$$

证明. NTD-PL 的参数由三部分组成:

1. 核心张量 $\mathcal{X} \in \mathbb{R}^{R_1 \times \dots \times R_N}$, 参数量为

$$\prod_{n=1}^N R_n; \quad (58)$$

2. 各模因子矩阵 $\mathbf{A}^{(n)} \in \mathbb{R}^{I_n \times R_n}$, 总参数量为

$$\sum_{n=1}^N I_n R_n; \quad (59)$$

3. 多项式链接系数 $\boldsymbol{\beta} = (\beta_0, \beta_1, \dots, \beta_P)^\top$, 参数量为

$$P + 1. \quad (60)$$

三部分相加即得

$$\#\text{param} = \prod_{n=1}^N R_n + \sum_{n=1}^N I_n R_n + (P + 1). \quad (61)$$

□

A.3 尺度不定性与归一化机制

下面说明 NTD-PL 继承了 Tucker 分解的尺度不定性, 因此正文中的归一化步骤可以理解作为一种规范化机制, 而非改变模型能力的额外约束。

命题 9 (尺度不变性). 设

$$\mathcal{S} = \llbracket \mathcal{X}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket. \quad (62)$$

对某一模 n , 取任意可逆对角矩阵 $D^{(n)} \in \mathbb{R}^{R_n \times R_n}$, 并定义

$$\tilde{\mathbf{A}}^{(n)} = \mathbf{A}^{(n)} D^{(n)}, \quad \tilde{\mathcal{X}} = \mathcal{X} \times_n (D^{(n)})^{-1}. \quad (63)$$

则有

$$\llbracket \tilde{\mathcal{X}}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(n-1)}, \tilde{\mathbf{A}}^{(n)}, \mathbf{A}^{(n+1)}, \dots, \mathbf{A}^{(N)} \rrbracket = \mathcal{S}. \quad (64)$$

因此, 对任意多项式系数 β , NTD-PL 输出

$$\hat{\mathcal{Y}} = f_{\beta}(\mathcal{S}) \quad (65)$$

保持不变。

证明. 由 Tucker 重构的模乘结合律,

$$(\mathcal{X} \times_n B) \times_n A = \mathcal{X} \times_n (AB),$$

可得

$$\llbracket \tilde{\mathcal{X}}; \mathbf{A}^{(1)}, \dots, \tilde{\mathbf{A}}^{(n)}, \dots, \mathbf{A}^{(N)} \rrbracket = \tilde{\mathcal{X}} \times_1 \mathbf{A}^{(1)} \times \dots \times_n \tilde{\mathbf{A}}^{(n)} \times \dots \times_N \mathbf{A}^{(N)} \quad (66)$$

$$= (\mathcal{X} \times_n (D^{(n)})^{-1}) \times_n (\mathbf{A}^{(n)} D^{(n)}) \times_{m \neq n} \mathbf{A}^{(m)} \quad (67)$$

$$= \mathcal{X} \times_n \left((\mathbf{A}^{(n)} D^{(n)}) (D^{(n)})^{-1} \right) \times_{m \neq n} \mathbf{A}^{(m)} \quad (68)$$

$$= \mathcal{X} \times_n \mathbf{A}^{(n)} \times_{m \neq n} \mathbf{A}^{(m)} \quad (69)$$

$$= \llbracket \mathcal{X}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket = \mathcal{S}. \quad (70)$$

因此, 共线缩放与核心吸收不会改变潜在张量 $\mathcal{S}$ 。由于 NTD-PL 的输出仅依赖于 $\mathcal{S}$,

$$\hat{\mathcal{Y}} = f_{\beta}(\mathcal{S}) = \sum_{p=0}^P \beta_p \mathcal{S}^{\odot p}, \quad (71)$$

故当 $\mathcal{S}$ 不变时, $\hat{\mathcal{Y}}$ 也保持不变。□

注 1. 命题 9 说明, 因子列归一化并将尺度吸收到核心张量中, 不会改变 NTD-PL 的输出, 只是从参数等价类中选取了一个更稳定的表示。由于高阶项 $\mathcal{S}^{\odot p}$ 对尺度更加敏感, 这种归一化在多项式链接模型中尤为重要。

B 逐元素非线性生成下的表达性分析

本节对应正文第 4.3.2 节, 给出 NTD-PL 在逐元素非线性生成模型下的基本表达性结论。为与正文一致, 设真实潜在 Tucker 张量为

$$\mathcal{S}^* = \llbracket \mathcal{X}^*; \mathbf{A}^{(1)*}, \dots, \mathbf{A}^{(N)*} \rrbracket \in \mathbb{R}^{I_1 \times \dots \times I_N}, \quad (72)$$

并记总元素个数为

$$N_e = \prod_{n=1}^N I_n. \quad (73)$$

设观测张量由某个标量函数 $g: \mathbb{R} \rightarrow \mathbb{R}$ 逐元素作用生成, 即

$$\mathcal{Y} = g(\mathcal{S}^*), \quad \mathcal{Y}_{i_1, \dots, i_N} = g(\mathcal{S}_{i_1, \dots, i_N}^*). \quad (74)$$

NTD-PL 的模型类写为

$$\hat{\mathcal{Y}} = f_{\beta}(\mathcal{S}) = \sum_{p=0}^P \beta_p \mathcal{S}^{\odot p}, \quad \mathcal{S} = \llbracket \mathcal{X}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket, \quad (75)$$

其中 $\mathcal{S}^{\odot p}$ 表示 $\mathcal{S}$ 的逐元素 p 次幂, $\beta = (\beta_0, \dots, \beta_P)$ 为多项式链接系数。

假设 1 (有界性假设). 存在常数 $B > 0$, 使得

$$\|\mathcal{S}^*\|_{\infty} \leq B. \quad (76)$$

假设 1 在实际中是自然的, 因为数据预处理与模型中的尺度规范化通常会将潜在 Tucker 张量控制在某个有界区间内。

B.1 多项式生成下的精确表达

定理 2 (多项式链接下的精确表达). 设真实生成函数 g 是次数不超过 P 的实系数多项式, 即

$$g(x) = \sum_{p=0}^P c_p x^p. \quad (77)$$

若真实观测张量满足

$$\mathcal{Y} = g(\mathcal{S}^*), \quad \mathcal{S}^* = \llbracket \mathcal{X}^*; \mathbf{A}^{(1)*}, \dots, \mathbf{A}^{(N)*} \rrbracket, \quad (78)$$

则 NTD-PL 在次数 P 下可以精确表示 $\mathcal{Y}$ 。更具体地, 只需取

$$\mathcal{X} = \mathcal{X}^*, \quad \mathbf{A}^{(n)} = \mathbf{A}^{(n)*} \quad (n = 1, \dots, N), \quad \beta_p = c_p \quad (p = 0, \dots, P), \quad (79)$$

便有

$$\hat{\mathcal{Y}} = \sum_{p=0}^P \beta_p (\mathcal{S}^*)^{\odot p} = g(\mathcal{S}^*) = \mathcal{Y}. \quad (80)$$

证明. 对任意索引 $(i_1, \dots, i_N)$, 有

$$\hat{\mathcal{Y}}_{i_1, \dots, i_N} = \sum_{p=0}^P c_p (\mathcal{S}_{i_1, \dots, i_N}^*)^p = g(\mathcal{S}_{i_1, \dots, i_N}^*) = \mathcal{Y}_{i_1, \dots, i_N}. \quad (81)$$

由于上述等式对所有元素均成立, 故 $\hat{\mathcal{Y}} = \mathcal{Y}$. □

推论 1 (多项式非线性下的精确恢复). 若真实生成满足

$$\mathcal{Y} = \mathcal{S}^* + \alpha h(\mathcal{S}^*), \quad (82)$$

其中 h 是次数不超过 d 的多项式函数, 则当 $P \geq d$ 时, 存在一组 NTD-PL 参数使得

$$\hat{\mathcal{Y}} = \mathcal{Y}. \quad (83)$$

证明. 将函数

$$g(x) = x + \alpha h(x) \quad (84)$$

视为次数不超过 $\max\{1, d\}$ 的多项式。若 $P \geq d$, 则 g 的次数不超过 P , 由定理 2 即得结论。 □

B.2 一般逐元素非线性下的逼近界

下面说明, 当真实非线性函数不是多项式时, NTD-PL 的逼近误差可以由一维标量函数逼近误差来控制。

定理 3 (由标量函数逼近诱导的张量逼近界). 设假设 1 成立, 并令

$$q_P(x) = \sum_{p=0}^P \beta_p x^p \quad (85)$$

为任意一个次数不超过 P 的多项式。若取 NTD-PL 的潜变量为真实潜变量, 即 $S = S^*$, 则有

$$\|g(S^*) - q_P(S^*)\|_F \leq \sqrt{N_e} \sup_{|x| \leq B} |g(x) - q_P(x)|. \quad (86)$$

证明. 对任意元素 $(i_1, \dots, i_N)$, 由 $\|S^*\|_\infty \leq B$ 可知

$$|g(S_{i_1, \dots, i_N}^*) - q_P(S_{i_1, \dots, i_N}^*)| \leq \sup_{|x| \leq B} |g(x) - q_P(x)|. \quad (87)$$

两边平方后对全部 N_e 个元素求和, 得

$$\|g(S^*) - q_P(S^*)\|_F^2 \leq N_e \left(\sup_{|x| \leq B} |g(x) - q_P(x)| \right)^2. \quad (88)$$

两边开方即可得到 (86)。 $\square$

注 2. 定理 3 表明, NTD-PL 在固定真实潜变量 S^* 时的张量近似问题, 可以归结为区间 $[-B, B]$ 上的一维函数逼近问题。因此, 当真实非线性为 $\sin(\cdot)$ 、 $\tanh(\cdot)$ 等解析函数时, 其效果取决于相应多项式截断在该区间上的逼近质量。

B.3 解析函数下的显式截断误差界

定理 4 (解析链接函数下的显式截断界). 设 g 在复圆盘

$$D(0, \rho) = \{z \in \mathbb{C} : |z| < \rho\} \quad (89)$$

内解析, 并满足

$$0 < B < \rho, \quad \|S^*\|_\infty \leq B. \quad (90)$$

设 g 在 0 点的 Taylor 展开为

$$g(x) = \sum_{p=0}^{\infty} a_p x^p, \quad (91)$$

取其 P 阶截断多项式

$$q_P(x) = \sum_{p=0}^P a_p x^p, \quad (92)$$

并定义

$$M_\rho = \sup_{|z|=\rho} |g(z)|. \quad (93)$$

则有

$$\|g(S^*) - q_P(S^*)\|_F \leq \sqrt{N_e} M_\rho \frac{(B/\rho)^{P+1}}{1 - B/\rho}. \quad (94)$$

证明. 由 Cauchy 估计知

$$|a_p| \leq \frac{M_\rho}{\rho^p}, \quad p = 0, 1, 2, \dots \quad (95)$$

于是对任意 $|x| \leq B$ 有

$$|g(x) - q_P(x)| = \left| \sum_{p=P+1}^{\infty} a_p x^p \right| \leq \sum_{p=P+1}^{\infty} |a_p| |x|^p \quad (96)$$

$$\leq M_\rho \sum_{p=P+1}^{\infty} (B/\rho)^p = M_\rho \frac{(B/\rho)^{P+1}}{1 - B/\rho}. \quad (97)$$

再由定理 3 即得

$$\|g(\mathcal{S}^*) - q_P(\mathcal{S}^*)\|_F \leq \sqrt{N_e} M_\rho \frac{(B/\rho)^{P+1}}{1 - B/\rho}. \quad (98)$$

证毕. $\square$

注 3. 定理 4 给出了一个显式误差界。它说明:

1. 当 P 增大时, 若 $B < \rho$, 则截断误差随 P 以几何速度衰减;
2. 在相同次数 P 下, 潜变量的幅值范围 B 越大, 逼近越困难;
3. 这为实验中不同非线性函数、不同非线性强度以及不同归一化策略下的性能差异提供了理论解释。

B.4 与非线性能量占比参数 α 的关系

本文合成数据中的非线性强度参数 α 采用的是能量占比定义, 而非直接的非线性项系数。设线性基底张量为

$$\mathcal{S}^* \in \mathbb{R}^{I_1 \times \dots \times I_N}, \quad (99)$$

并令

$$\mathcal{X}^* = g(\mathcal{S}^*) \quad (100)$$

表示某个逐元素非线性变换后的张量。为避免将 $\mathcal{X}^*$ 中沿 $\mathcal{S}^*$ 的线性分量重复计入非线性部分, 先定义其正交化残差为

$$\mathcal{R}^* = \mathcal{X}^* - \frac{\langle \mathcal{X}^*, \mathcal{S}^* \rangle}{\|\mathcal{S}^*\|_F^2} \mathcal{S}^*. \quad (101)$$

若 $\|\mathcal{R}^*\|_F > 0$, 再定义归一化残差

$$\tilde{\mathcal{R}}^* = \frac{\|\mathcal{S}^*\|_F}{\|\mathcal{R}^*\|_F} \mathcal{R}^*. \quad (102)$$

于是观测张量构造为

$$\mathcal{Y}_\alpha = \sqrt{1-\alpha} \mathcal{S}^* + \sqrt{\alpha} \tilde{\mathcal{R}}^*, \quad 0 \leq \alpha \leq 1. \quad (103)$$

上述构造与实现中采用的生成方式一致: 先从非线性变换中去掉沿线性基底的投影, 再将残差缩放到与原张量相同的目标能量, 最后按 $\sqrt{1-\alpha}$ 与 $\sqrt{\alpha}$ 做能量混合。

命题 10 (能量占比解释). 设 $\mathcal{Y}_\alpha$ 由式 (103) 定义, 且 $\|\mathcal{R}^*\|_F > 0$ 。则有

$$\langle \mathcal{S}^*, \tilde{\mathcal{R}}^* \rangle = 0, \quad \|\tilde{\mathcal{R}}^*\|_F = \|\mathcal{S}^*\|_F, \quad (104)$$

从而

$$\|\mathcal{Y}_\alpha\|_F^2 = \|\mathcal{S}^*\|_F^2, \quad (105)$$

且线性部分与非线性部分的能量占比分别满足

$$\frac{\|\sqrt{1-\alpha} \mathcal{S}^*\|_F^2}{\|\mathcal{Y}_\alpha\|_F^2} = 1 - \alpha, \quad \frac{\|\sqrt{\alpha} \tilde{\mathcal{R}}^*\|_F^2}{\|\mathcal{Y}_\alpha\|_F^2} = \alpha. \quad (106)$$

证明. 由式 (101) 可知

$$\langle \mathcal{S}^*, \mathcal{R}^* \rangle = 0, \quad (107)$$

故

$$\langle \mathcal{S}^*, \tilde{\mathcal{R}}^* \rangle = 0. \quad (108)$$

又由式 (102) 有

$$\|\tilde{\mathcal{R}}^*\|_F = \|\mathcal{S}^*\|_F. \quad (109)$$

于是

$$\|\mathcal{Y}_\alpha\|_F^2 = \left\| \sqrt{1-\alpha} \mathcal{S}^* + \sqrt{\alpha} \tilde{\mathcal{R}}^* \right\|_F^2 \quad (110)$$

$$= (1-\alpha) \|\mathcal{S}^*\|_F^2 + \alpha \|\tilde{\mathcal{R}}^*\|_F^2 + 2\sqrt{\alpha(1-\alpha)} \langle \mathcal{S}^*, \tilde{\mathcal{R}}^* \rangle \quad (111)$$

$$= (1-\alpha) \|\mathcal{S}^*\|_F^2 + \alpha \|\mathcal{S}^*\|_F^2 \quad (112)$$

$$= \|\mathcal{S}^*\|_F^2, \quad (113)$$

即得式 (105)。再分别计算两部分能量占总能量的比例，即得式 (106)。 $\square$

下面分析在这种能量占比定义下，NTD-PL 的截断误差如何随 α 变化。

推论 2 (截断误差与 α 的关系). 设

$$\mathcal{X}^* = g(\mathcal{S}^*), \quad \|\mathcal{S}^*\|_\infty \leq B, \quad (114)$$

并令

$$c_g = \frac{\langle \mathcal{X}^*, \mathcal{S}^* \rangle}{\|\mathcal{S}^*\|_F^2}, \quad \eta_g = \frac{\|\mathcal{S}^*\|_F}{\|\mathcal{R}^*\|_F}, \quad (115)$$

其中 $\mathcal{R}^*$ 由式 (101) 定义。若 q_P 是 g 在区间 $[-B, B]$ 上的一个次数不超过 P 的多项式逼近，满足

$$\varepsilon_P(B) := \sup_{|s| \leq B} |g(s) - q_P(s)|, \quad (116)$$

并定义

$$a_\alpha = \sqrt{1-\alpha} - \sqrt{\alpha} \eta_g c_g, \quad b_\alpha = \sqrt{\alpha} \eta_g, \quad (117)$$

则存在一个对应的 *degree-P* 表示

$$\hat{\mathcal{Y}}_{\alpha,P} = a_\alpha \mathcal{S}^* + b_\alpha q_P(\mathcal{S}^*), \quad (118)$$

满足

$$\|\mathcal{Y}_\alpha - \hat{\mathcal{Y}}_{\alpha,P}\|_F \leq \sqrt{\alpha} \eta_g \sqrt{N_e} \varepsilon_P(B), \quad (119)$$

其中

$$N_e = \prod_{n=1}^N I_n. \quad (120)$$

进一步地,

$$\|\mathcal{Y}_\alpha - \hat{\mathcal{Y}}_{\alpha,P}\|_F^2 \leq \alpha \eta_g^2 N_e \varepsilon_P(B)^2. \quad (121)$$

证明. 由式 (101)–(102) 有

$$\tilde{\mathcal{R}}^* = \eta_g (\mathcal{X}^* - c_g \mathcal{S}^*) = \eta_g (g(\mathcal{S}^*) - c_g \mathcal{S}^*). \quad (122)$$

代入式 (103), 得

$$\mathcal{Y}_\alpha = \sqrt{1-\alpha} \mathcal{S}^* + \sqrt{\alpha} \eta_g (g(\mathcal{S}^*) - c_g \mathcal{S}^*) \quad (123)$$

$$= (\sqrt{1-\alpha} - \sqrt{\alpha} \eta_g c_g) \mathcal{S}^* + \sqrt{\alpha} \eta_g g(\mathcal{S}^*) \quad (124)$$

$$= a_\alpha \mathcal{S}^* + b_\alpha g(\mathcal{S}^*). \quad (125)$$

因此

$$\mathcal{Y}_\alpha - \hat{\mathcal{Y}}_{\alpha,P} = b_\alpha (g(\mathcal{S}^*) - q_P(\mathcal{S}^*)). \quad (126)$$

由 $|b_\alpha| = \sqrt{\alpha} \eta_g$ 以及

$$\|g(\mathcal{S}^*) - q_P(\mathcal{S}^*)\|_F \leq \sqrt{N_e} \varepsilon_P(B) \quad (127)$$

可得

$$\|\mathcal{Y}_\alpha - \hat{\mathcal{Y}}_{\alpha,P}\|_F \leq \sqrt{\alpha} \eta_g \sqrt{N_e} \varepsilon_P(B). \quad (128)$$

两边平方即得式 (121)。 $\square$

注 4. 推论 2 表明, 在本文采用的能量占比生成机制下:

1. Frobenius 范数意义下的截断误差上界随 $\sqrt{\alpha}$ 缩放;
2. 平方误差以及 NMSE 型指标的上界随 α 缩放;
3. 若 g 本身就是次数不超过 P 的多项式, 则 $\varepsilon_P(B) = 0$, 此时对任意 $\alpha \in [0, 1]$ 都有精确表示;
4. 若 g 为解析函数, 则截断误差除了受 α 影响外, 还受多项式次数 P 、输入幅值范围 B 以及解析半径共同影响。

其中, 系数

$$\eta_g = \frac{\|\mathcal{S}^*\|_F}{\|\mathcal{R}^*\|_F} \quad (129)$$

还反映了真实非线性中“正交非线性残差”的有效强度: 当非线性残差较弱时, 为达到同样的能量占比 α , 相应残差方向需要被放大更多, 因此有限阶多项式近似也会更加困难。

注 5. 当 $\|\mathcal{R}^*\|_F = 0$ 时, 说明所选非线性变换在当前输入上未产生有效的非线性残差, 此时生成过程退化为纯线性情形, α 不再改变观测张量的方向结构。

C 优化补充

C.1 β 子问题的唯一解

本节对应正文第 4.4 节, 证明在 $\lambda_\beta > 0$ 时, NTD-PL 中的多项式链接系数 β 子问题存在唯一解。固定潜在张量

$$\mathcal{S} = \llbracket \mathcal{X}; \mathbf{A}^{(1)}, \dots, \mathbf{A}^{(N)} \rrbracket, \quad (130)$$

当前多项式次数 P 以及观测集合 Ω , 考虑如下优化问题:

$$\min_{\beta \in \mathbb{R}^{P+1}} \left\| \Omega \odot \left(\mathcal{Y} - \sum_{p=0}^P \beta_p \mathcal{S}^{\odot p} \right) \right\|_F^2 + \lambda_\beta \|\beta\|_2^2, \quad \lambda_\beta > 0. \quad (131)$$

记 $M_\Omega = |\Omega|$, 将观测条目拉平后, 可得观测向量

$$\mathbf{y}_\Omega \in \mathbb{R}^{M_\Omega}, \quad (132)$$

以及对应的潜在张量取值

$$\mathbf{s}_\Omega = (s_1, \dots, s_{M_\Omega})^\top \in \mathbb{R}^{M_\Omega}. \quad (133)$$

据此构造设计矩阵

$$\Phi_\Omega = \begin{bmatrix} 1 & s_1 & s_1^2 & \cdots & s_1^P \\ 1 & s_2 & s_2^2 & \cdots & s_2^P \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & s_{M_\Omega} & s_{M_\Omega}^2 & \cdots & s_{M_\Omega}^P \end{bmatrix} \in \mathbb{R}^{M_\Omega \times (P+1)}. \quad (134)$$

于是式 (131) 可改写为标准 ridge regression:

$$\min_{\boldsymbol{\beta} \in \mathbb{R}^{P+1}} \|\mathbf{y}_\Omega - \Phi_\Omega \boldsymbol{\beta}\|_2^2 + \lambda_\beta \|\boldsymbol{\beta}\|_2^2. \quad (135)$$

命题 11 (正则化 $\boldsymbol{\beta}$ 子问题的唯一解). 当 $\lambda_\beta > 0$ 时, 问题 (135) 存在唯一最优解, 且

$$\boldsymbol{\beta}^* = (\Phi_\Omega^\top \Phi_\Omega + \lambda_\beta I)^{-1} \Phi_\Omega^\top \mathbf{y}_\Omega. \quad (136)$$

证明. 定义目标函数

$$f(\boldsymbol{\beta}) = \|\mathbf{y}_\Omega - \Phi_\Omega \boldsymbol{\beta}\|_2^2 + \lambda_\beta \|\boldsymbol{\beta}\|_2^2. \quad (137)$$

将其展开, 可得

$$f(\boldsymbol{\beta}) = \mathbf{y}_\Omega^\top \mathbf{y}_\Omega - 2\mathbf{y}_\Omega^\top \Phi_\Omega \boldsymbol{\beta} + \boldsymbol{\beta}^\top \Phi_\Omega^\top \Phi_\Omega \boldsymbol{\beta} + \lambda_\beta \boldsymbol{\beta}^\top \boldsymbol{\beta}. \quad (138)$$

因此其梯度为

$$\nabla f(\boldsymbol{\beta}) = 2(\Phi_\Omega^\top \Phi_\Omega + \lambda_\beta I) \boldsymbol{\beta} - 2\Phi_\Omega^\top \mathbf{y}_\Omega, \quad (139)$$

Hessian 为

$$\nabla^2 f(\boldsymbol{\beta}) = 2(\Phi_\Omega^\top \Phi_\Omega + \lambda_\beta I). \quad (140)$$

由于 $\Phi_\Omega^\top \Phi_\Omega$ 半正定, 而 $\lambda_\beta I$ 在 $\lambda_\beta > 0$ 时正定, 所以

$$\Phi_\Omega^\top \Phi_\Omega + \lambda_\beta I \succ 0. \quad (141)$$

从而 $f(\boldsymbol{\beta})$ 是严格凸函数, 因此存在唯一极小点. 令梯度为零, 得到正规方程

$$(\Phi_\Omega^\top \Phi_\Omega + \lambda_\beta I) \boldsymbol{\beta} = \Phi_\Omega^\top \mathbf{y}_\Omega. \quad (142)$$

由于系数矩阵正定可逆, 故唯一解为

$$\boldsymbol{\beta}^* = (\Phi_\Omega^\top \Phi_\Omega + \lambda_\beta I)^{-1} \Phi_\Omega^\top \mathbf{y}_\Omega. \quad (143)$$

证毕. $\square$

注 6. 命题 11 表明, 在固定潜在张量 $\mathcal{S}$ 时, $\boldsymbol{\beta}$ 更新是一个低维、强凸且有闭式解的子问题。特别地, 唯一性不再依赖于观测值是否足够丰富, 也不要求设计矩阵 Φ_Ω 满列秩; 正则项 $\lambda_\beta I$ 直接保证了系统矩阵的可逆性。这也是正则化在缺失观测和高阶多项式情形下尤为重要原因。

D 实验补充图表

本节补充正文第 5 章中用于辅助说明实验现象的图表。

D.1 合成实验补充




图 11: 线性一致性实验中的配对差值分布。图中比较不同设置下 Tucker 与 NTD-PL 的逐随机种子配对误差间隙, 用于补充正文表 1 的场景均值结论。可以看到, 在 $\text{bias}=0$ 时, 不引入常数项的 NTD-PL 与 Tucker 的配对差值基本集中在零附近; 而在存在仿射偏置时, β_0 受限的模型与 Tucker 之间出现更明显的系统性间隙。




图 12: 固定二维 Tucker 局部 patch 时, 不同多项式最高阶数 P 下学习到的局部响应图与相对 $P = 1$ 的偏差图。上排展示局部响应, 下排展示相对线性基线的偏差。

D.2 真实高光谱实验补充




图 13: CAVE 随机缺失补全的代表性空间可视化。各列依次为原图、带掩膜的观测输入、Tucker 补全、NTD-PL 补全、Tucker 的 missing-only 误差、NTD-PL 的 missing-only 误差，以及 missing-only 误差下降图。最后一列按 $\text{Tucker} - \text{NTD-PL}$ 定义，正值表示 NTD-PL 在缺失位置上进一步降低了补全误差。